CNNS

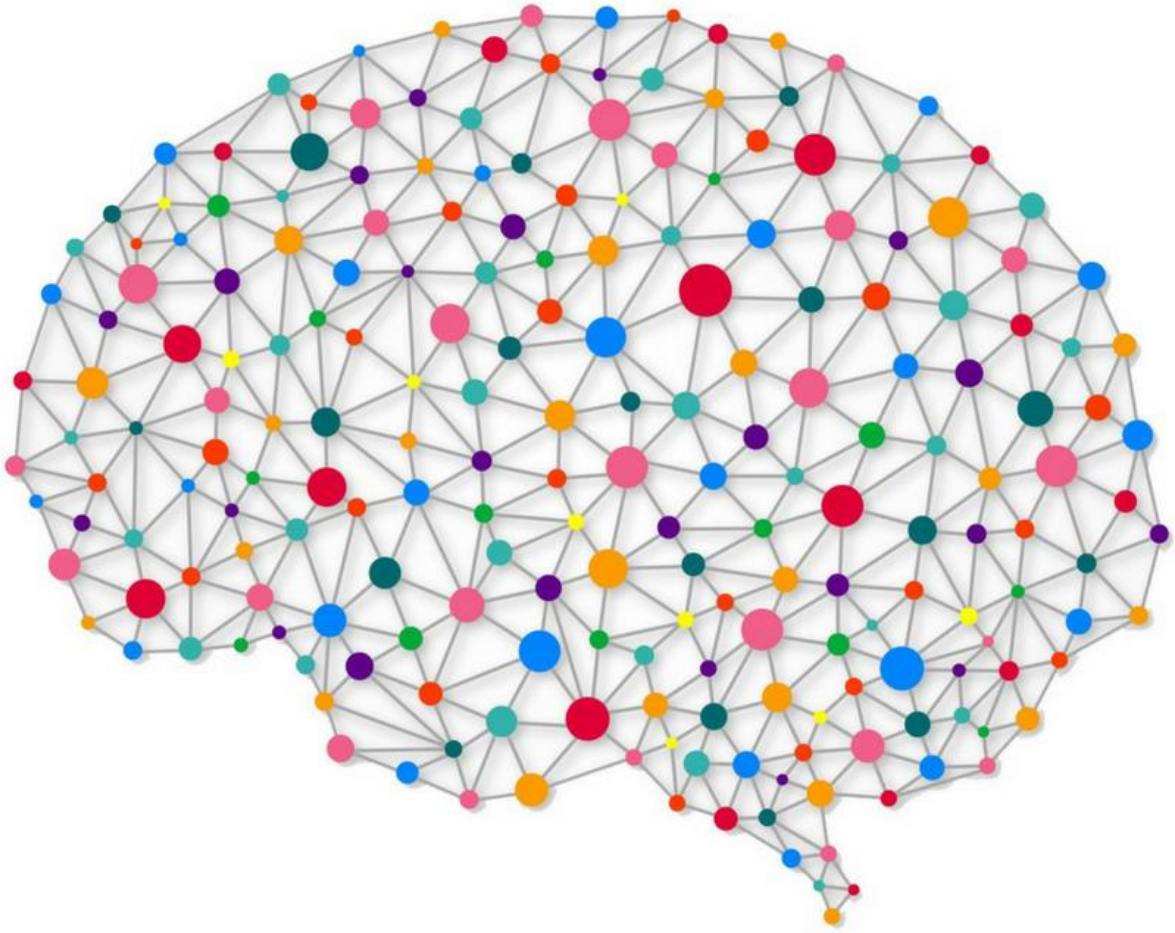

Javier Diaz Cely, PhD

UNIVERSIDAD ICESI

AGENDA

Aplicaciones

Aprendizaje no supervisado

Deep Learning

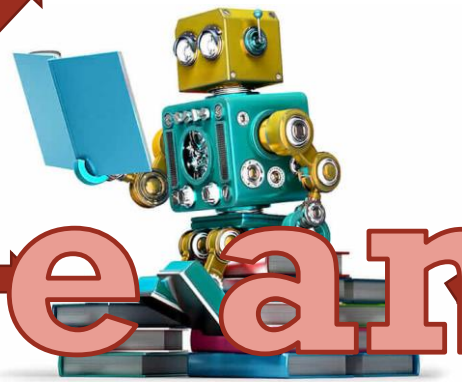

Machine Learning (Aprendizaje Automático)

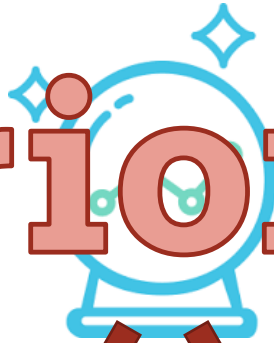

Aprendizaje supervisado

Clase anterior

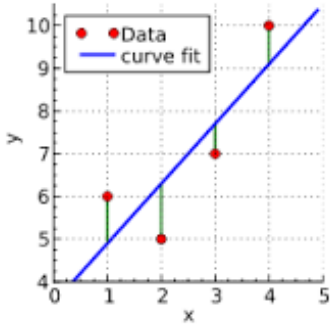

Mínimos cuadrados ordinarios

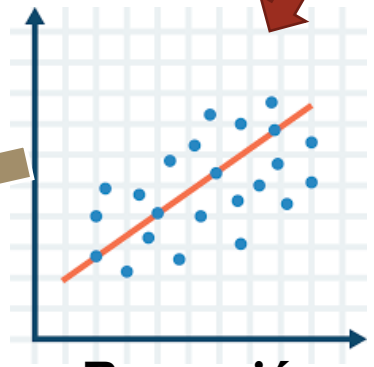

Regresión

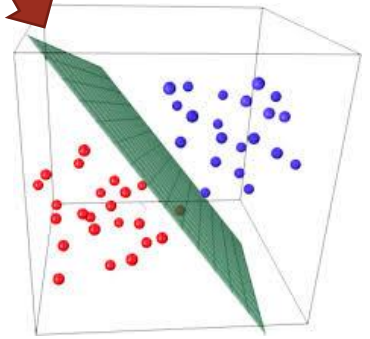

Clasificación

UNIVERSIDAD ICESI

AGENDA

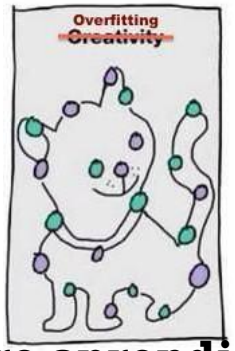

Sobre aprendizaje (Overfitting)

Protocolos de evaluación

Deep Learning

Clase anterior

Aprendizaje supervisado

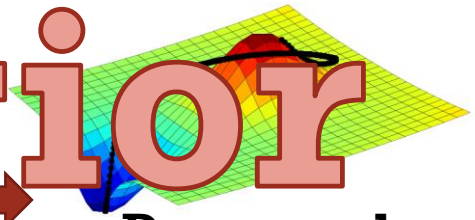

Descenso de gradiente

Métricas de Evaluación de la clasificación

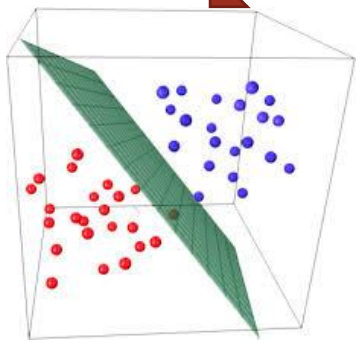

Clasificación

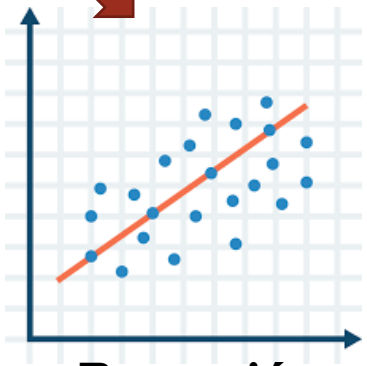

Regresión

UNIVERSIDAD ICESI

AGENDA

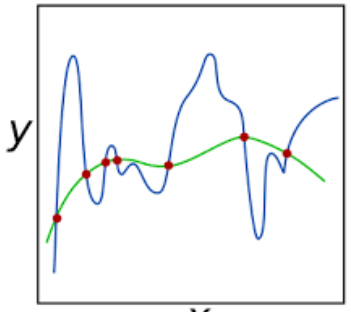

Regularización

Clase anterior

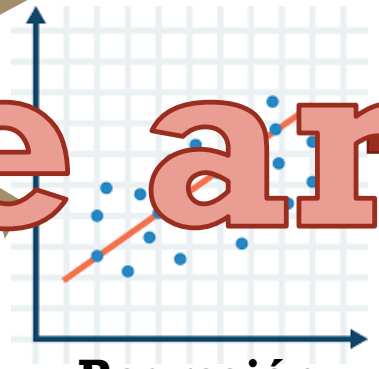

Regresión

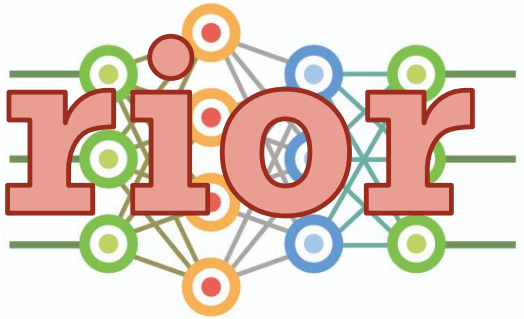

Red Neuronal Artificial (ANN)

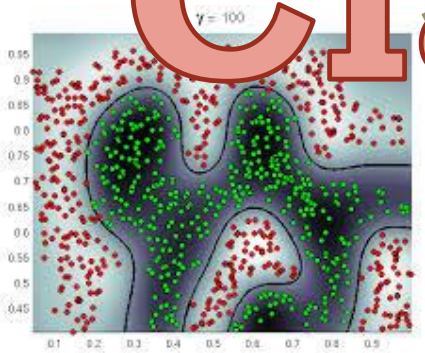

Aprendizaje supervisado

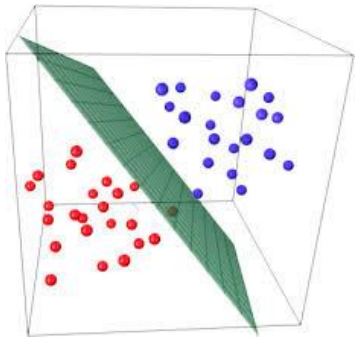

Clasificación

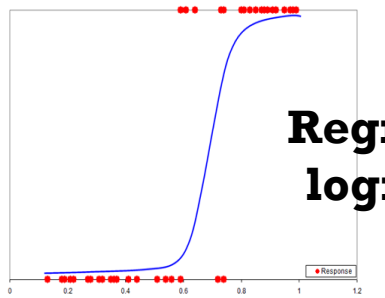

Regresión logística

UNIVERSIDAD ICESI

AGENDA

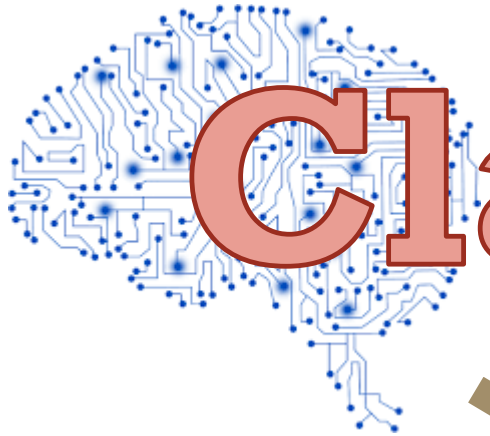

Deep Learning

Keras

TensorFlow

Clase anterior

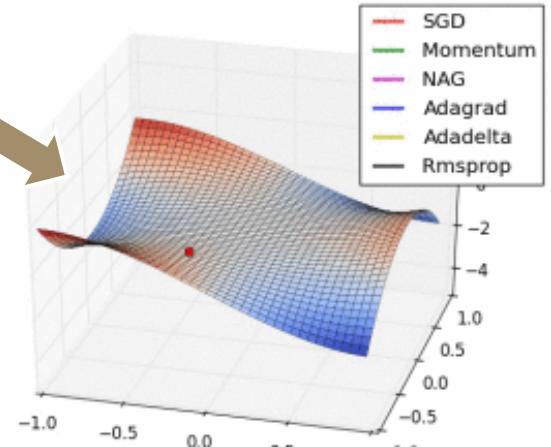

Optimizadores

UNIVERSIDAD ICESI

AGENDA

Deep Learning

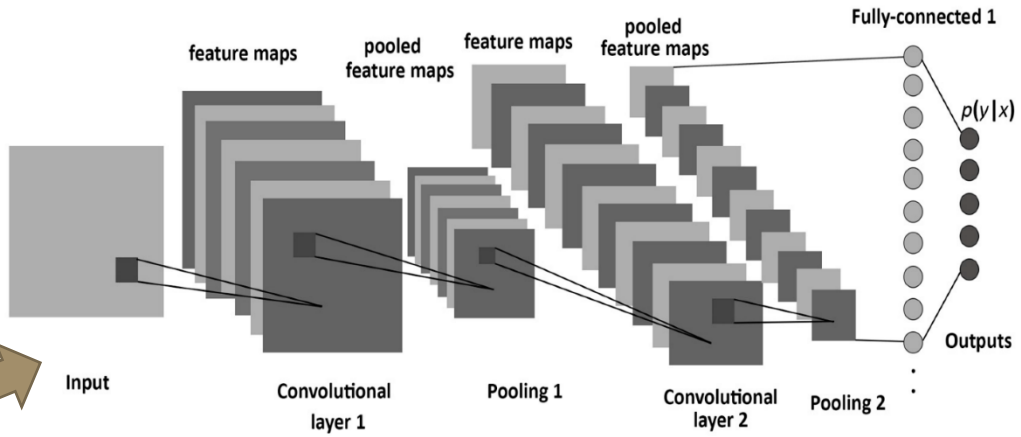

Redes convolucionales

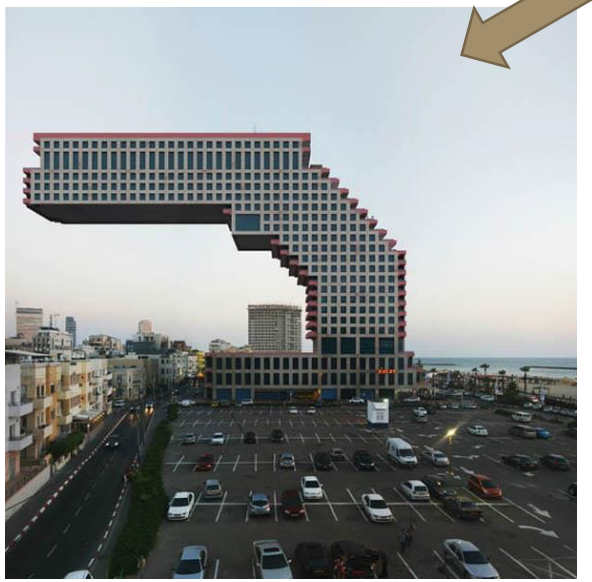

Arquitecturas convolucionales

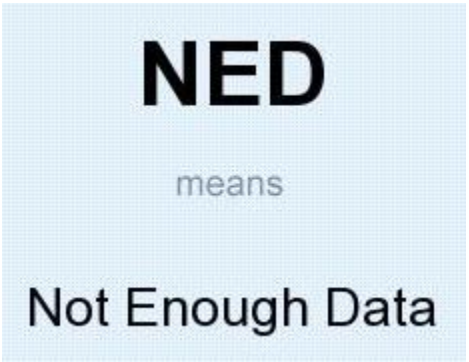

Limitaciones de datos

UNIVERSIDAD ICESI

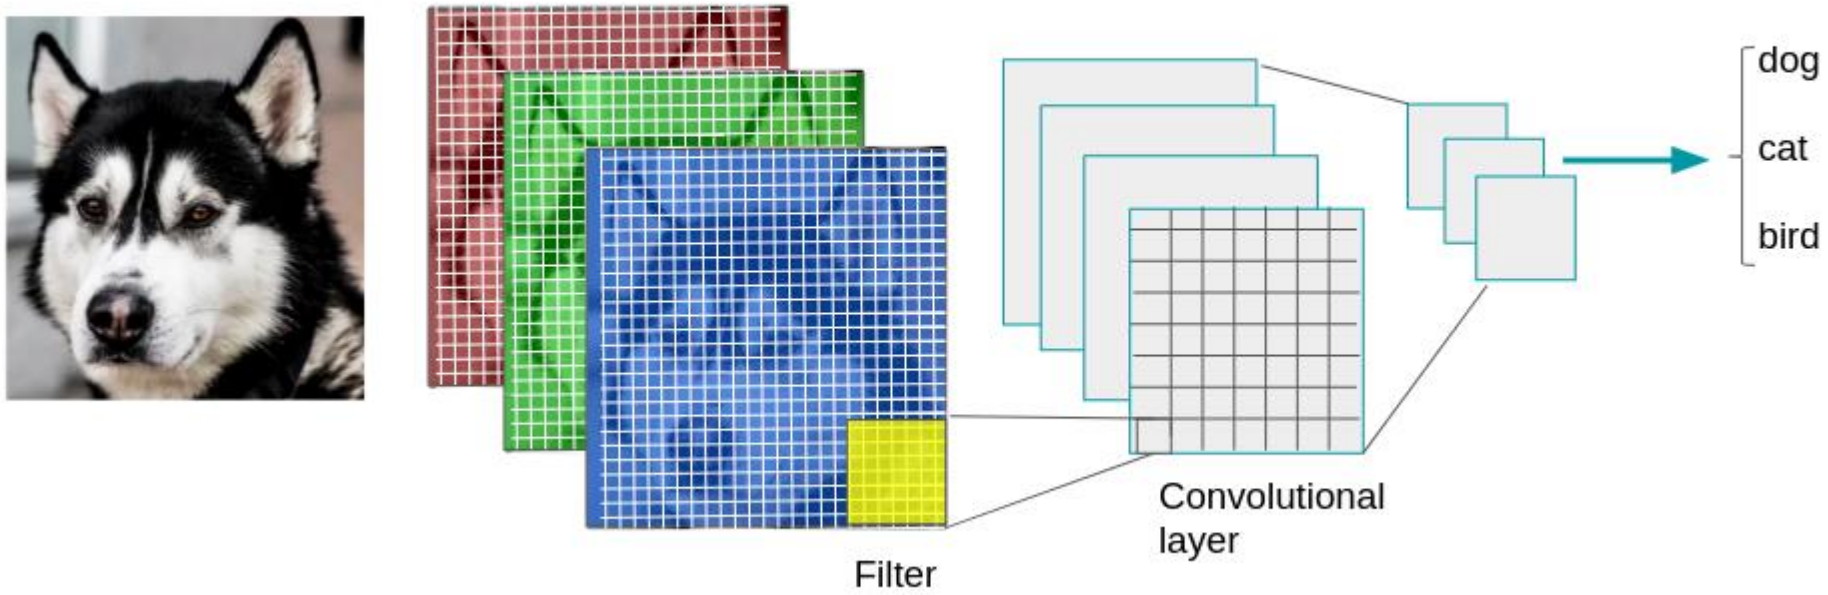

CNN – REDES CONVOLUCIONALES

UNIVERSIDAD ICESI

REDES CONVOLUCIONALES

- La arquitectura de las redes neuronales convolucionales (**CNNs** – Convolutional Neural Networks) es muy diferente al de las redes basadas en capas **densas**.
- La arquitectura se basa en la idea de diferentes niveles de **abstracción jerárquicos** que permiten encontrar nuevas representaciones (**features**) de los datos de entrada orientados a responder al objetivo de entrenamiento del modelo
- Aunque su desarrollo surgió en el campo de **visión por computador**, tienen múltiples campos de aplicación
- Se inspiran de diferentes campos como la **Biólogia y neuro ciencia,** el **tratamiento de imágenes** y la **teoría del aprendizaje y el machine learning**.

REDES CONVOLUCIONALES

Motivaciones, inspiración:

- **Biólogia, neuro ciencia**: el proceso de la visión en el cerebro comienza por la aplicación de los mismos filtros básicos a todo el campo visual (Hubel & Wiesel, premio Nobel 1960)

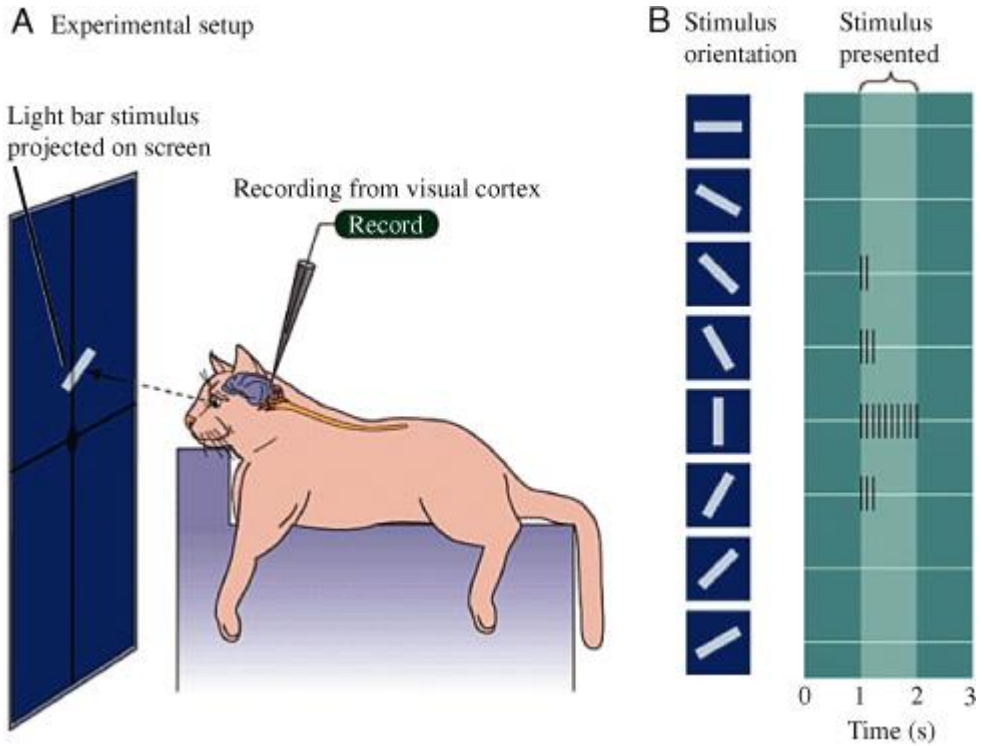

http://www.informit.com/articles/article.aspx?p=1431818

UNIVERSIDAD ICESI

REDES CONVOLUCIONALES

Motivaciones, inspiración:

- **Tratamiento de imágenes**: el reconocimiento de un objeto en una imagen debe ser independiente de:
  - la posición (traslación) y ángulo (rotación)
  - diferencias de tamaño
  - diferencias de iluminación
  - leves deformaciones o distorsiones

→Propiedad de **invarianza**

→Repetir operaciones de detección locales en diferentes partes de la imagen

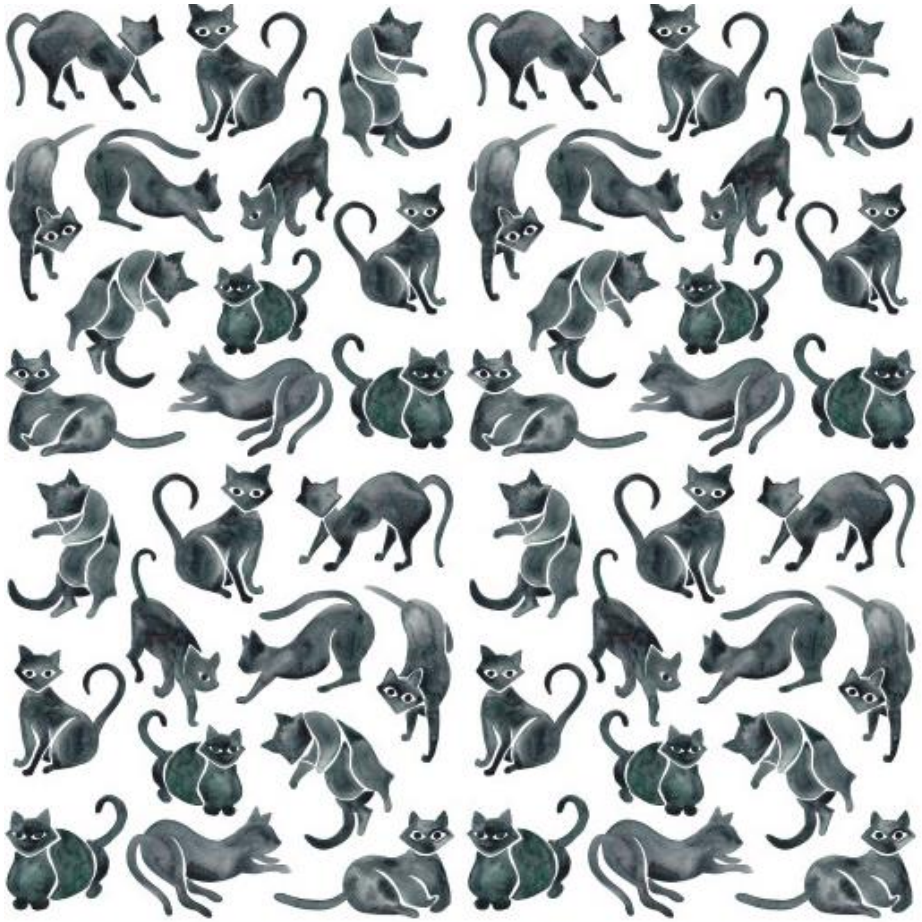

Society6.com

REDES CONVOLUCIONALES

Motivaciones, inspiración:

- **Teoría del aprendizaje, machine learning**: una capa densa otorga demasiada importancia a inputs particulares de la capa anterior, sometiendo los resultados a una dependencia de los mismos.
- Se debería buscar la generalización de los resultados con pequeñas capas densas aplicadas a subconjuntos de los inputs en busca de una **regularización** del modelo

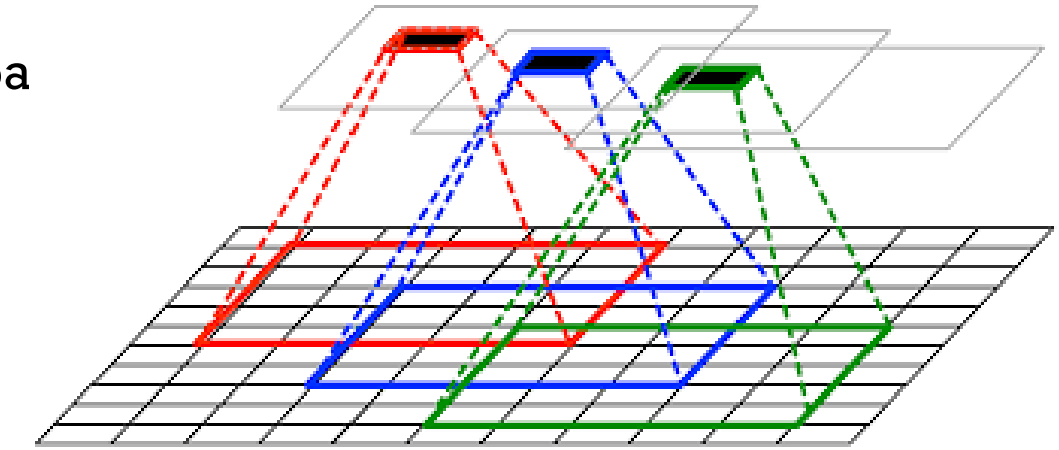

https://arxiv.org/pdf/1512.07108.pdf

REDES CONVOLUCIONALES – 1D

- Una **capa convolucional** consiste en **filtros** que realizan barridos en subregiones de la capa anterior (→ ventanas 1D, 2D, 3D, etc.), que se deslizan sobre las neuronas de la capa anterior).
  El entrenamiento consiste en determinar los pesos de los filtros mas adecuados para la tarea de aprendizaje.

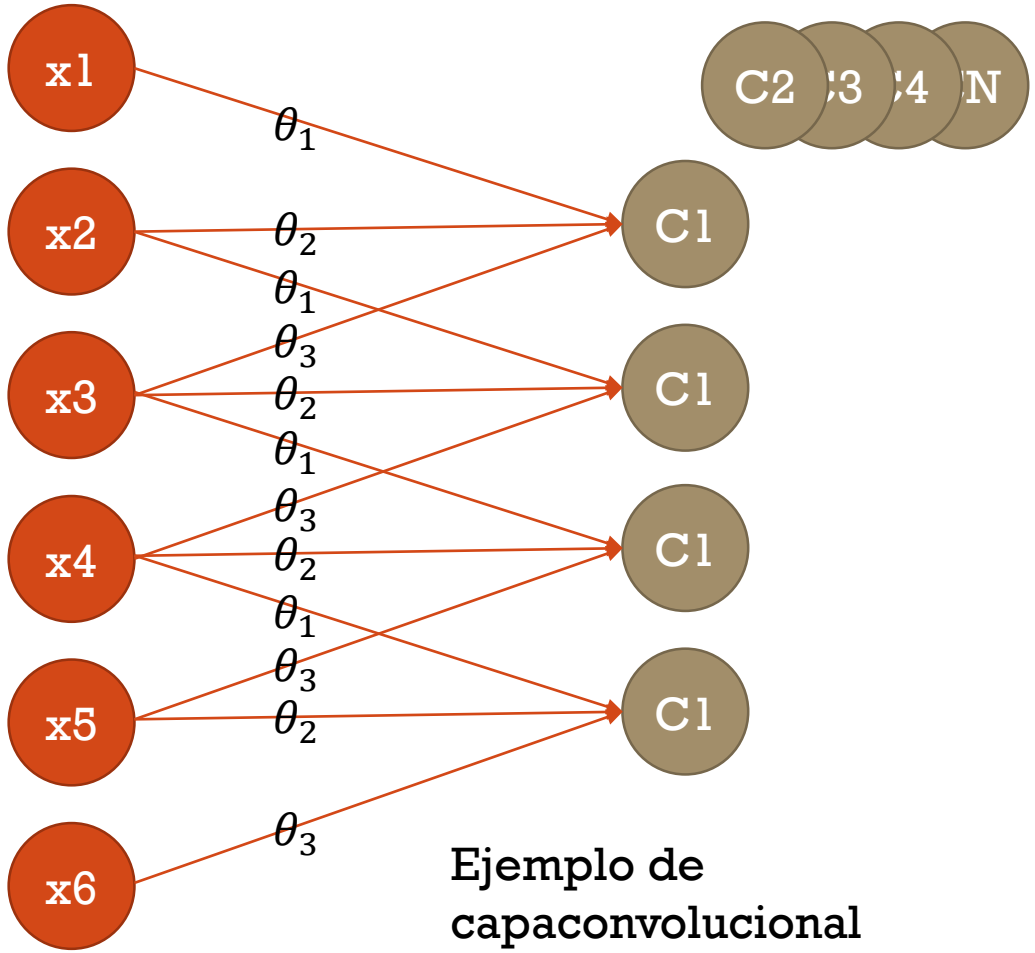

Ejemplo de capaconvolucional 1D

UNIVERSIDAD ICESI

REDES CONVOLUCIONALES – 2D (IMÁGENES)

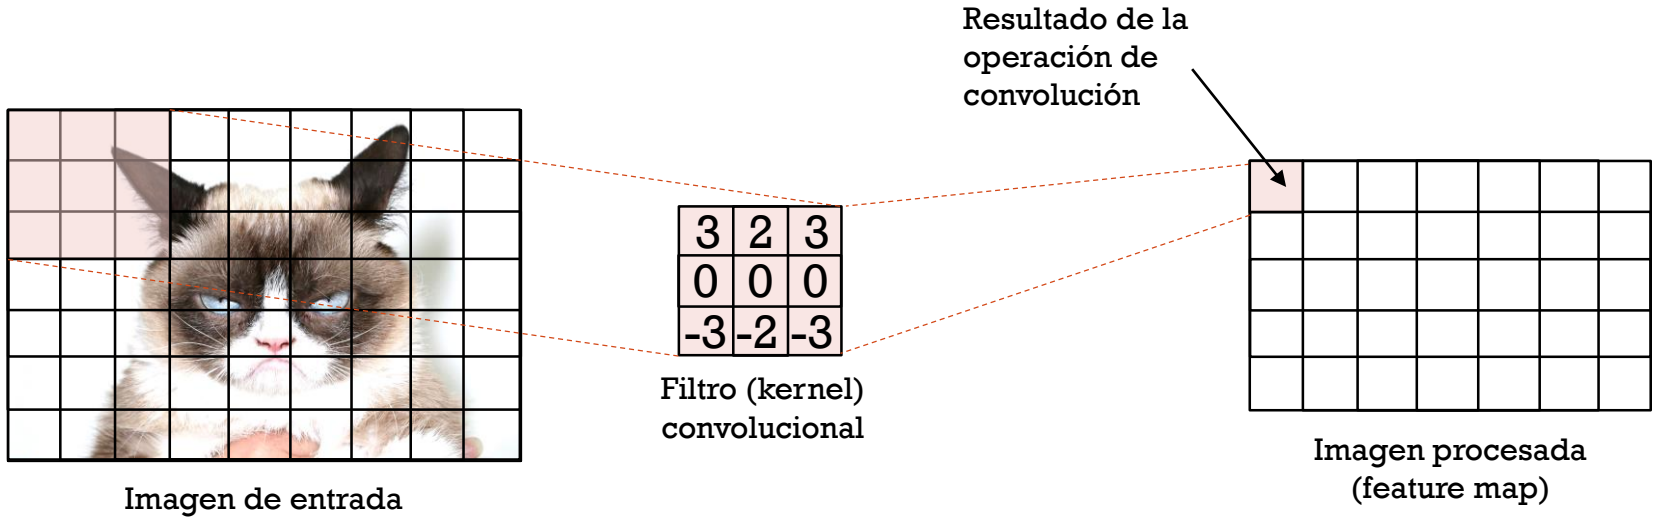

UNIVERSIDAD ICESI

REDES CONVOLUCIONALES – 2D (IMÁGENES)

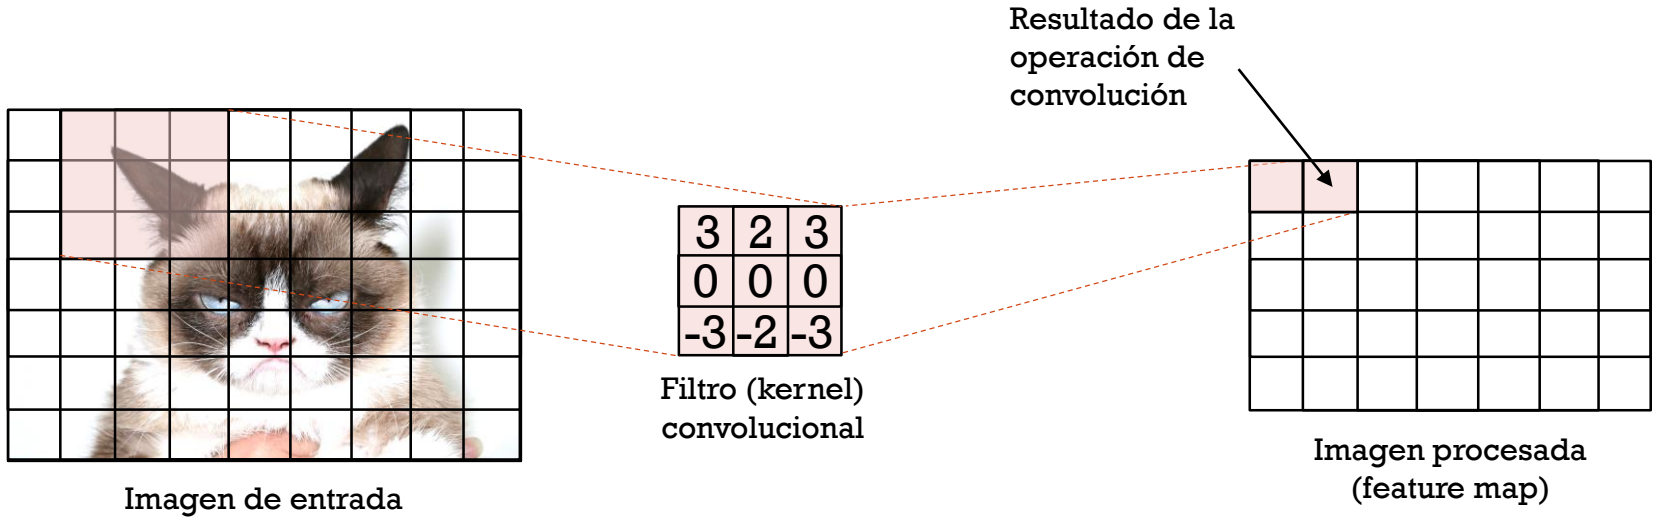

UNIVERSIDAD ICESI

REDES CONVOLUCIONALES – 2D (IMÁGENES)

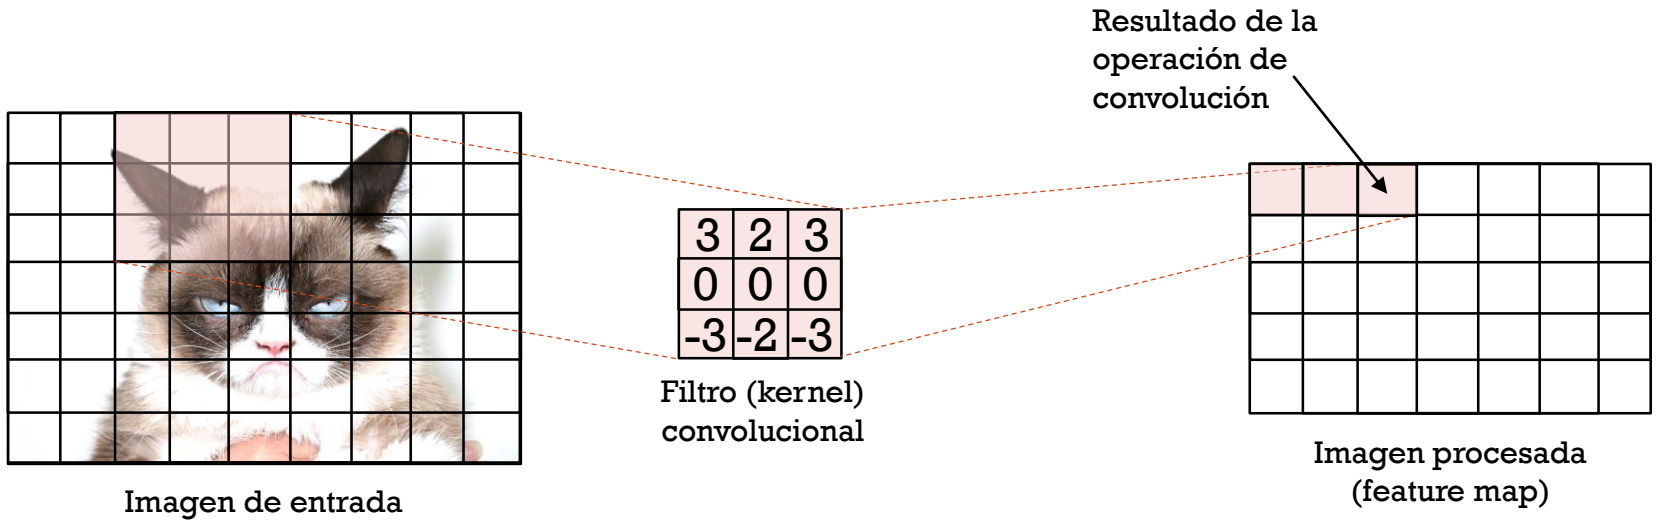

UNIVERSIDAD ICESI

REDES CONVOLUCIONALES – 2D (IMÁGENES)

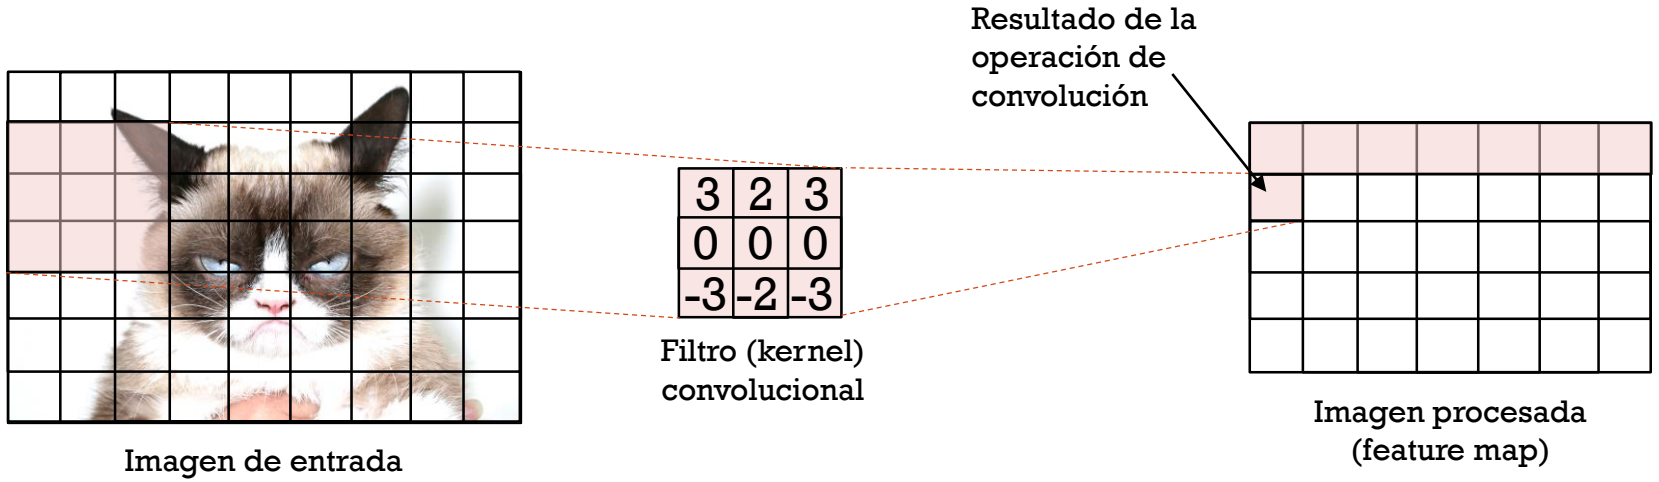

UNIVERSIDAD ICESI

REDES CONVOLUCIONALES – 2D (IMÁGENES)

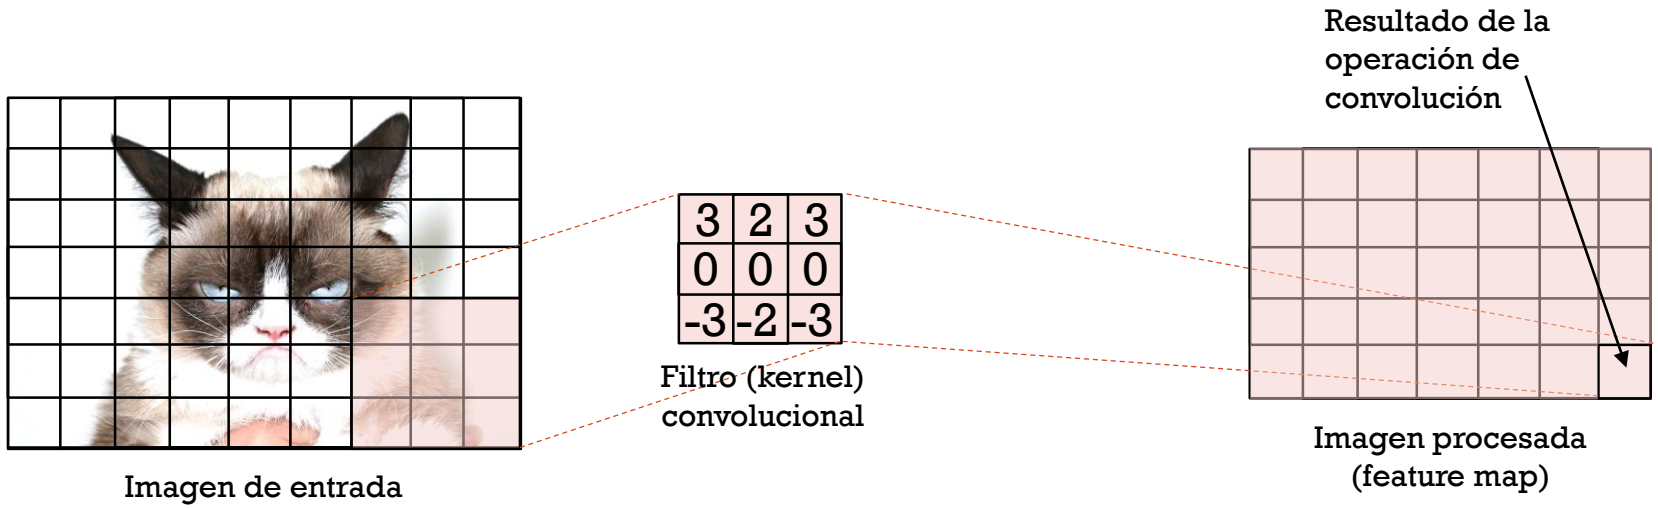

UNIVERSIDAD ICESI

REDES CONVOLUCIONALES – 2D (IMÁGENES)

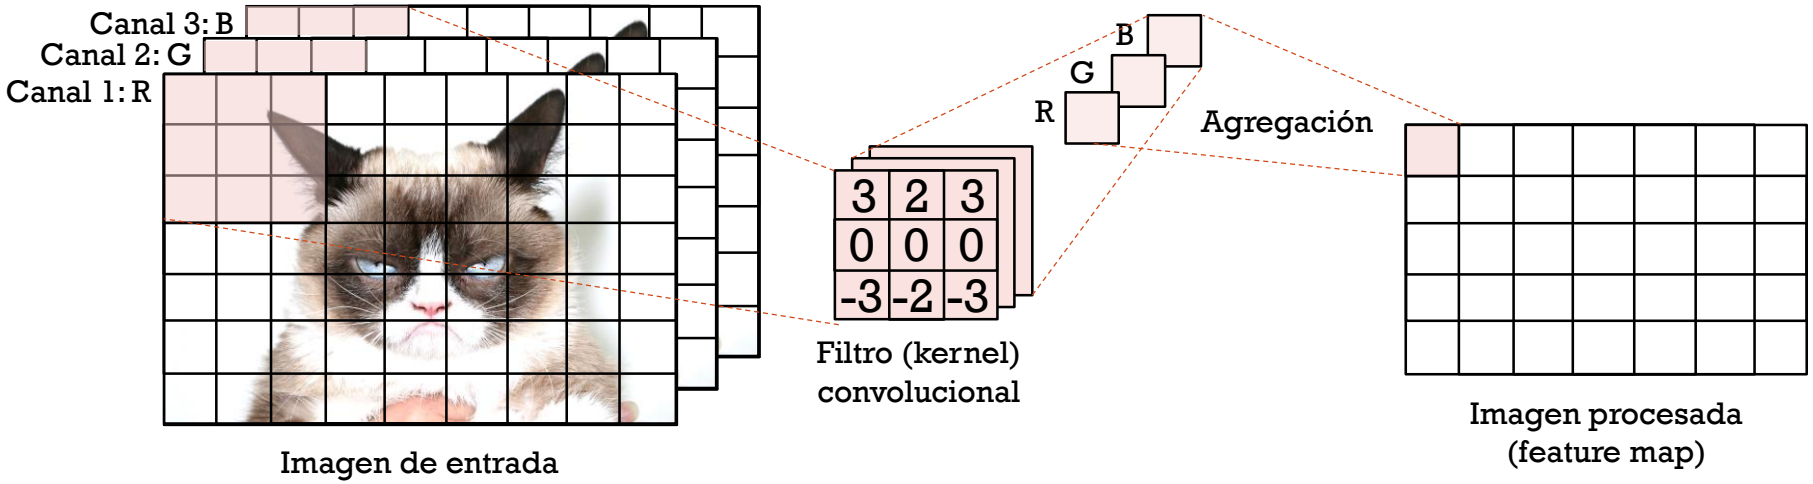

Múltiples canales (profundidad) de entrada:
los filtros tienen la misma profundidad

REDES CONVOLUCIONALES – 2D (IMÁGENES)

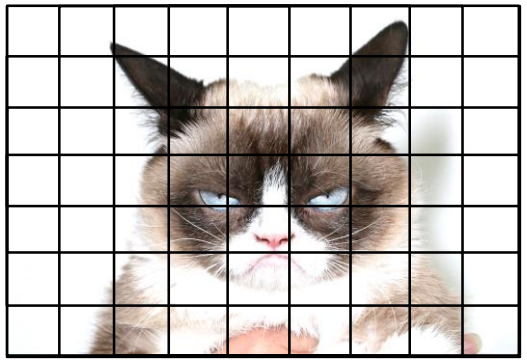

Imagen de entrada

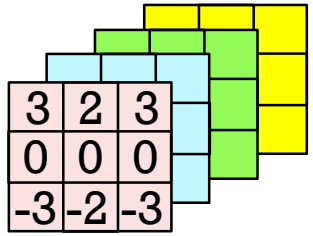

Filtro (kernel) convolucional

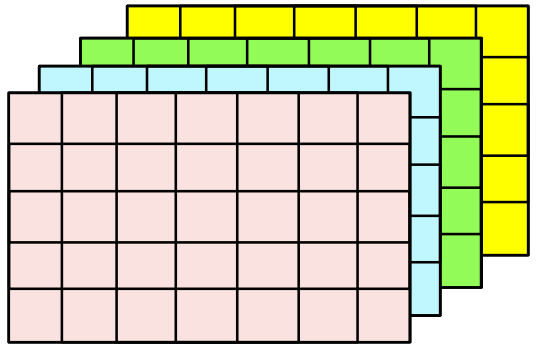

Imagen procesada (feature map)

Múltiples filtros convolucionales en la misma capa

UNIVERSIDAD ICESI

TALLER CONVOLUCIONES EN EXCEL

Desarrollar las 2 operaciones de convolución, encontrando los feature maps correspondientes.

UNIVERSIDAD ICESI

REDES CONVOLUCIONALES

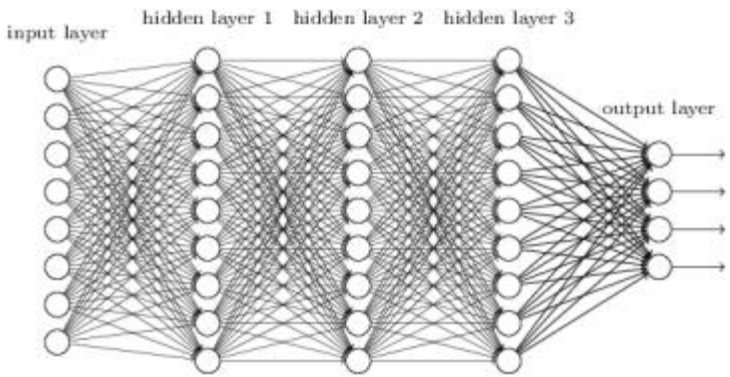

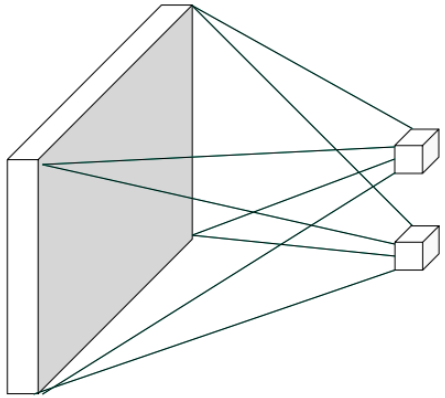

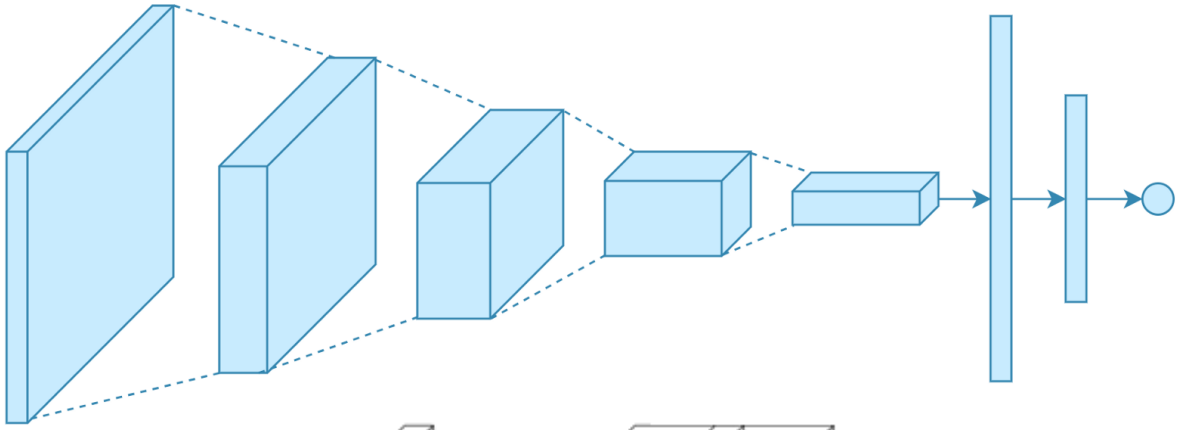

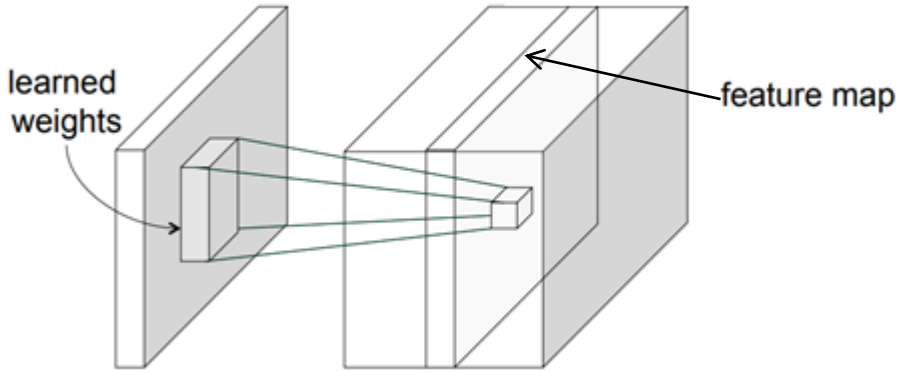

http://slazebni.cs.illinois.edu/spring17/lec01_cnn_architectures.pdf

REDES CONVOLUCIONALES

- Las redes convolucionales están comúnmente compuestas de **capas convolucionales** que se utilizan como extractores de features, que al final son "aplanados" y utilizados como inputs de **capas densas** tradicionales que permiten realizar por ejemplo tareas de detección de objetos.

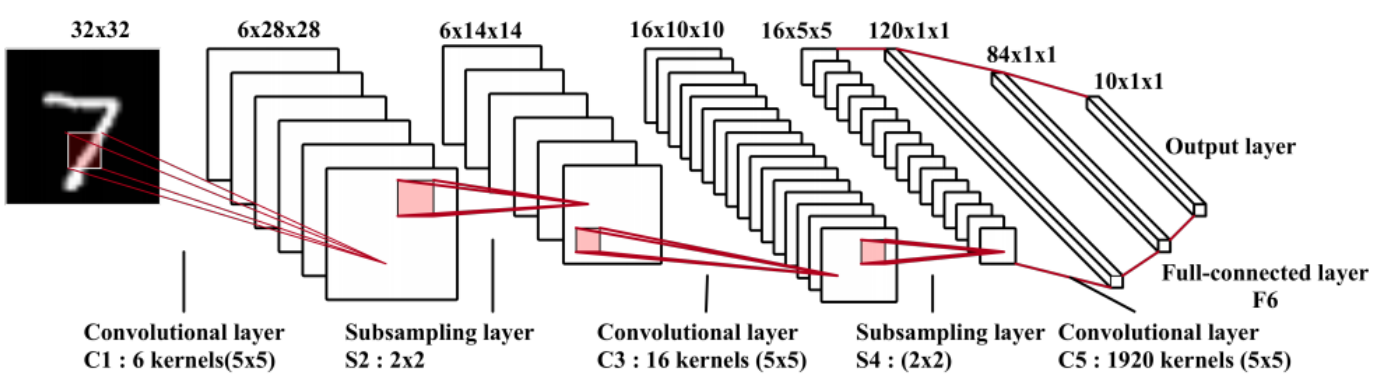

(a) LeNet-5 network

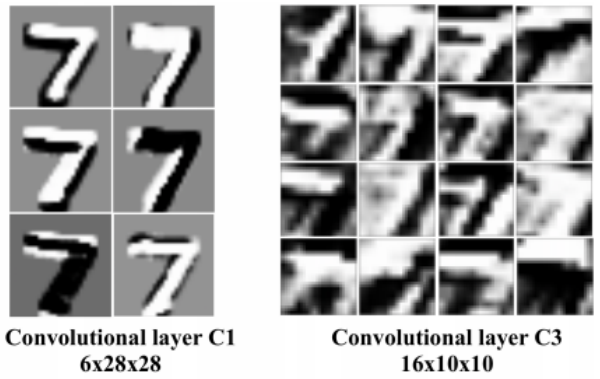

(b) Learned features

https://arxiv.org/pdf/1512.07108.pdf

UNIVERSIDAD ICESI

REDES CONVOLUCIONALES

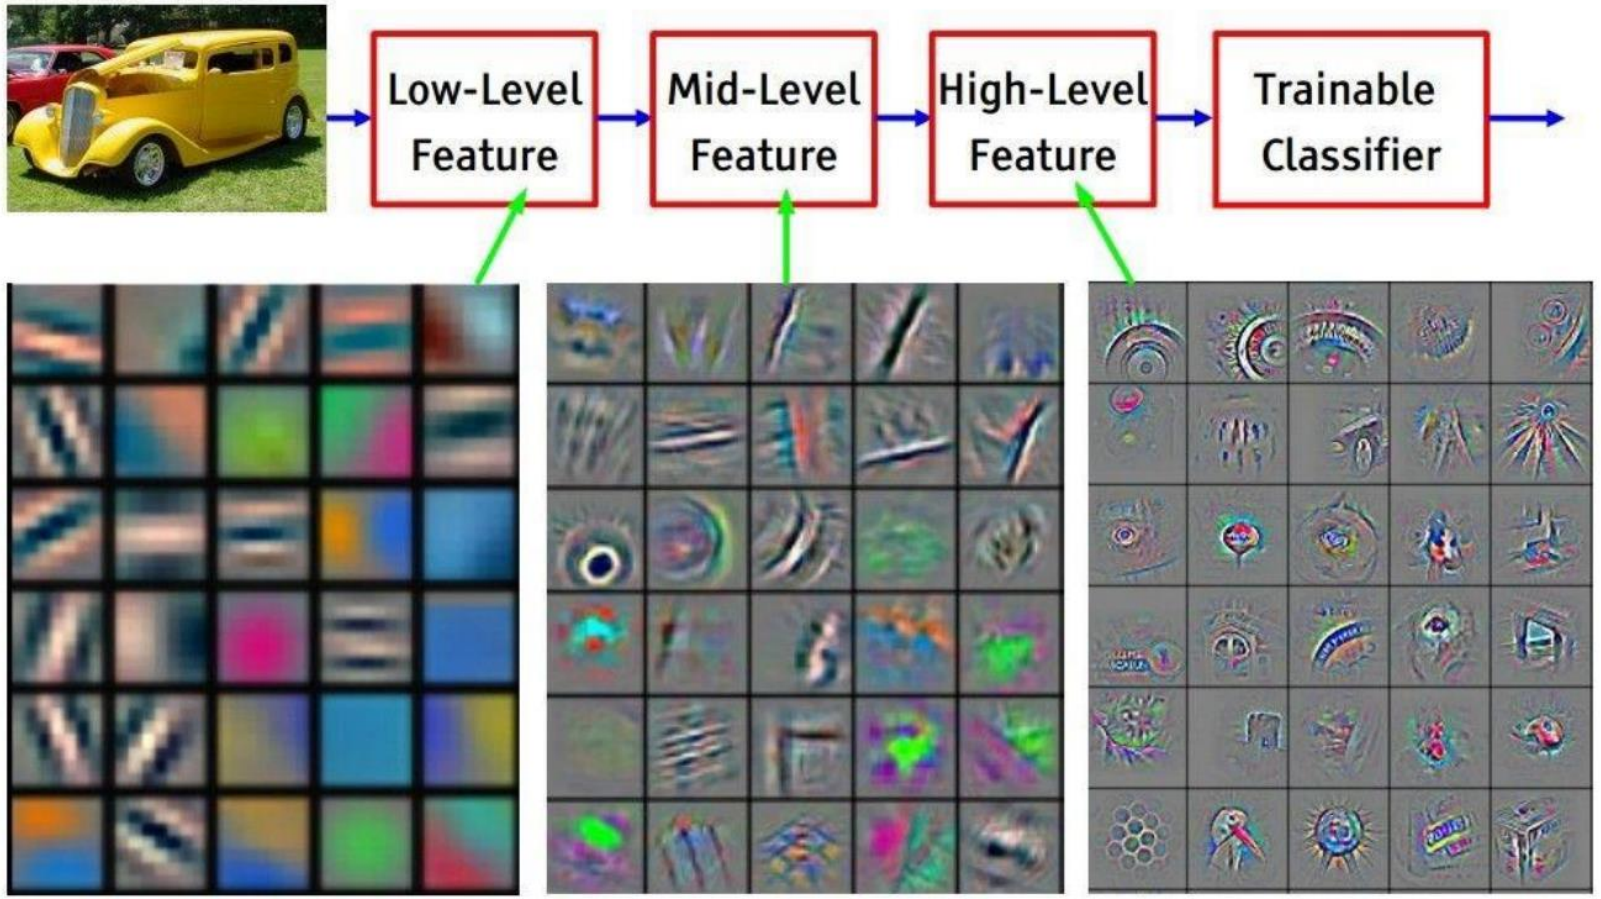

Feature visualization of convolutional net trained on ImageNet from [Zeiler & Fergus 2013]

UNIVERSIDAD ICESI

REDES CONVOLUCIONALES

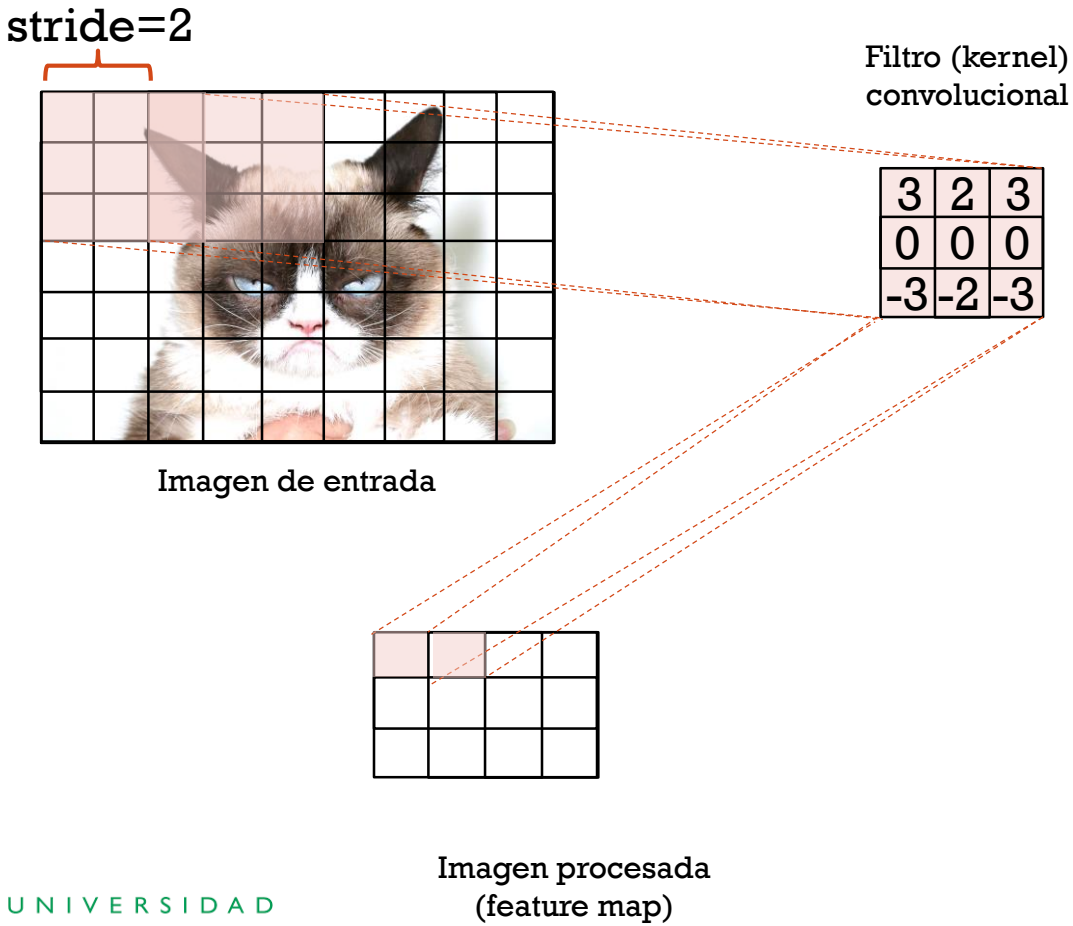

- **Stride**: Controla el barrido de los kernels convolucionales al atravesar los inputs.
- Entre más grande el stride: más pequeño el feature map resultante
- A un stride de 1 se le llama "FULL" stride
- Se debe definir el stride para cada una de las dimensiones de los datos de entrada
- ¿Cuál sería el tamaño de los feature maps con stride 1 para filtros de 3x3 y de 5x5?

→ El tamaño del filtro influye en el tamaño del feature map

UNIVERSIDAD ICESI

REDES CONVOLUCIONALES

Padding = SAME, stride =1

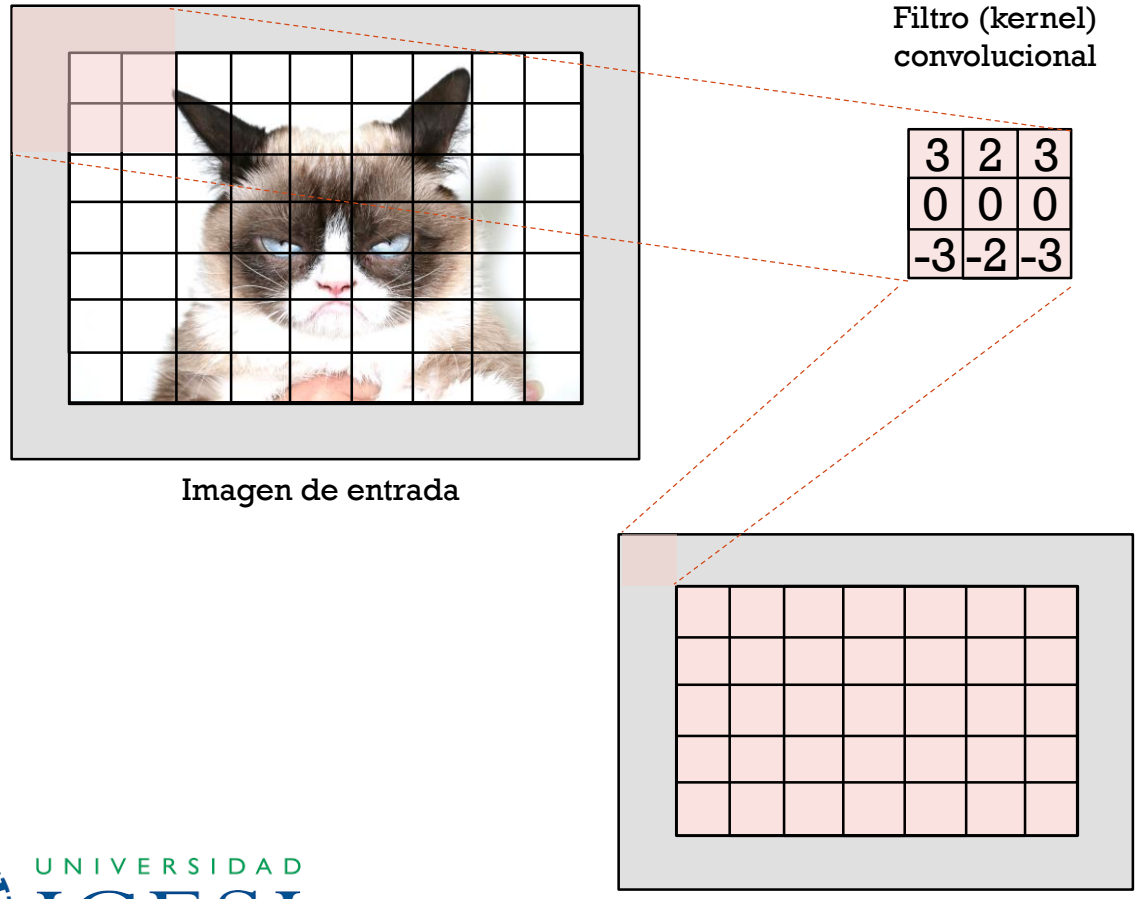

- **Padding**: Para contrarrestar la reducción del tamaño de las entradas después de una convolución se puede "rellenar" los extremos de las mismas con datos ficticios que idealmente no influyan en los resultados
- Cuando no hay padding, se le llama "**VALID**", los datos de los extremos superiores se ignoran (e.g. últimas columnas y filas en una imagen)
- A un padding que conserva el tamaño de las entradas cuando se tiene un stride de 1 se le llama "**SAME**". Si el número de dimensiones es impar, se agregan datos en los extremos superiores

REDES CONVOLUCIONALES

- Si se tiene un stride de 1, y se quiere tener una salida que conserve las dimensiones de entrada, el padding a utilizar es: $ZeroPadding = \frac{K-1}{2}$
- Tanto el tamaño del kernel, como el stride y el padding influyen en el tamaño de los feature maps generados.
- La formula que los une es la siguiente:

$$O = \frac{(W - K + 2P)}{S} + 1 \,,$$

donde:

O = Tamaño del feature map

W = Tamaño de los inputs

K = Tamaño del kernel

P = Tamaño del borde del padding

S = Stride

UNIVERSIDAD ICESI

REDES CONVOLUCIONALES

Pooling (2, 2), stride=1

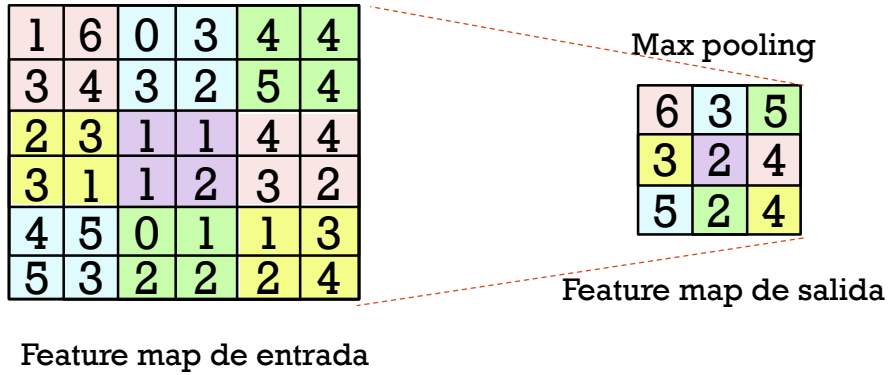

- **Pooling**: capas que permiten reducir la dimensionalidad de los feature maps y del número de parámetros de la red
  - Ventanas de agregación con **stride** y **padding**
  - Se aplican a menudo después de las capas convolucionales
  - Las funciones de agregación más usadas son Max, Average, L2-Norm
  - Simplifica la red (→ overfitting), reduciendo importancia a datos intermedios buscando robustez e invarianza de traslación a pequeños cambios de los inputs (e.g. efecto de mover a la derecha los pixeles de una imagen)
  - Permite reducir el número de parámetros, y otorgar a las capas posteriores una visión mas amplia de los datos originales

REDES CONVOLUCIONALES

- **Dropout**: Técnica de regularización para luchar contra el overfitting
  - Forzar aleatoriamente un porcentaje de las neuronas de una capa a "apagarse" cambiando sus activaciones a 0.

    → Necesidad de hiper-parámetro de probabilidad de dropout (e.g. 50%)
  - Solo se debe aplicar durante el entrenamiento (nunca durante la predicción), y las neuronas a "apagar" se actualizan para cada instancia de aprendizaje
  - Solo se debe aplicar a capas **densas** (fully-connected). En las capas **convolucionales** se puede utilizar una regularización L2.

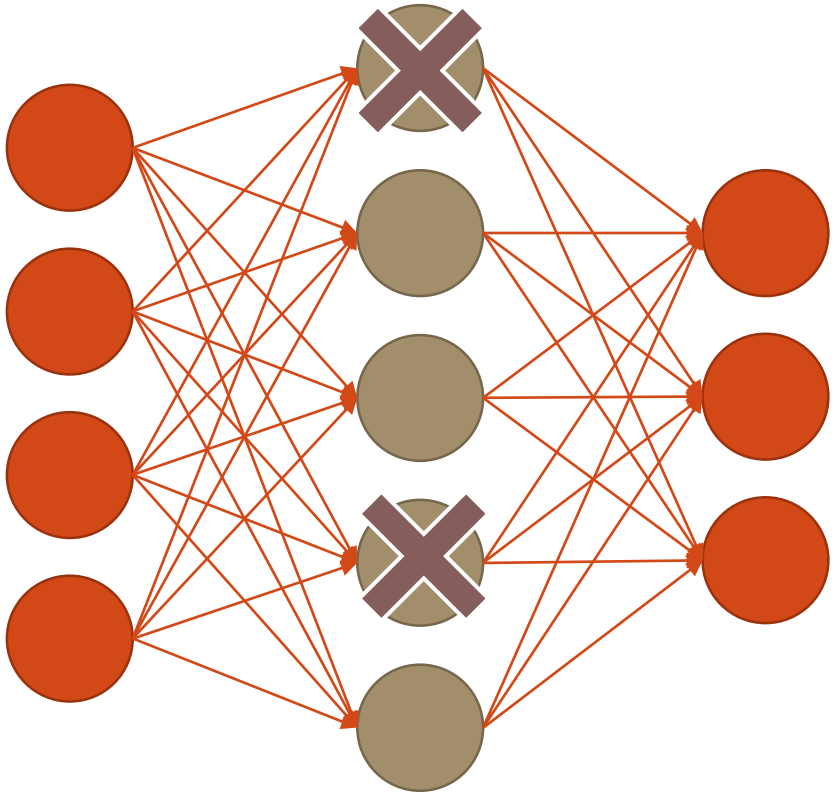

Dropout (p=40%)

AGENDA

Deep Learning

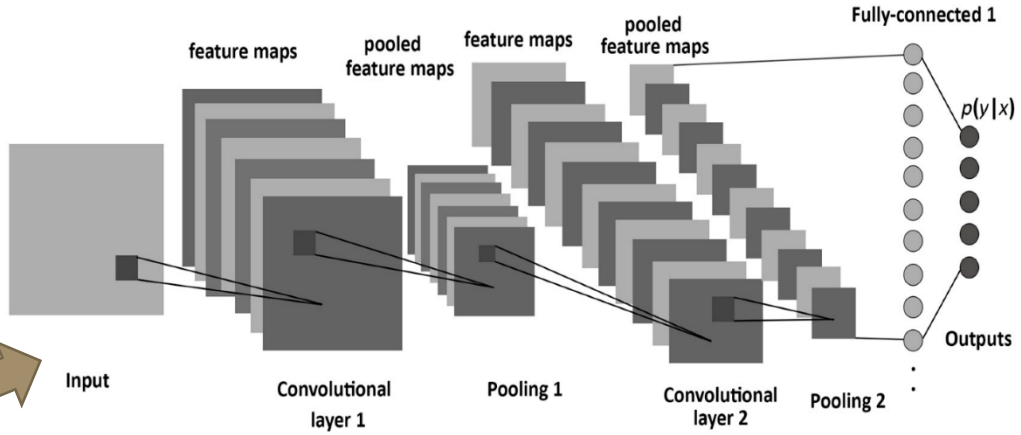

Redes convolucionales

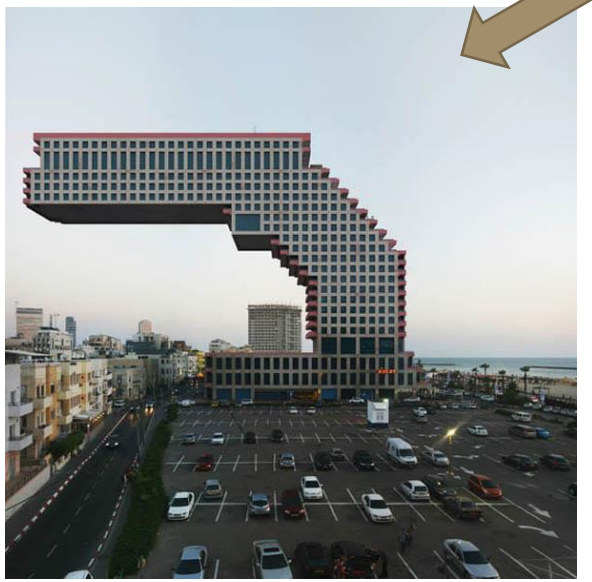

Arquitecturas convolucionales

UNIVERSIDAD ICESI

ARQUITECTURAS CONVOLUCIONALES

UNIVERSIDAD ICESI

LENET-5

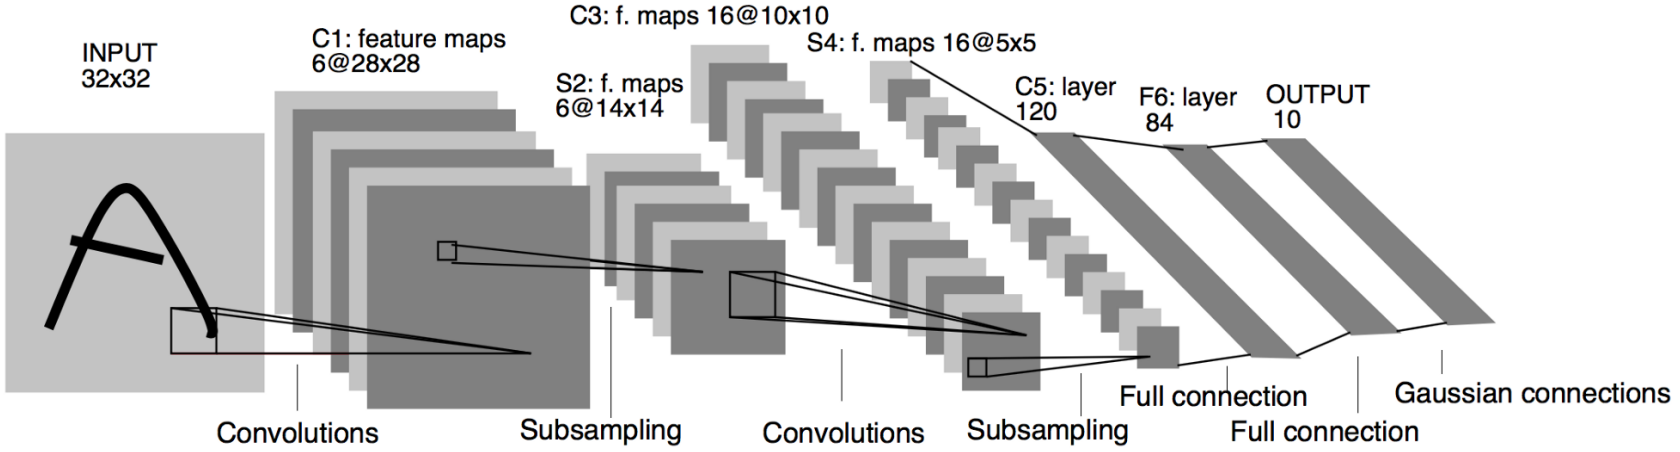

- Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, Gradient-based learning applied to document recognition, Proc. IEEE 86(11): 2278–2324, 1998.
  - MNIST 60000 ejemplos en escala de grises.
  - Utilizaba funciones de activación sigmoides y tanh. Aún no se usaba la ReLU.
  - En la época no se usaba Padding ni Dropout, y se aplicaba una función no lineal después de las capas de Pooling.
  - La capa final utilizaba una técnica que ya no se usa aplicando distribuciones gausianas para cada dígito.
- Arquitectura:
  - 2 capas convolucionales con filtros 5x5 con stride de 1, seguidas cada una de average pooling 2x2 con stride de 2. (28*28*1*+6)=4710 params + (10*10*1*16+16)=1616 params
  - Se aplana la salida convolucional (5x5x16 = 400 neuronas) y se conecta con capas densas sucesivas de 120, 84 y 10 neuronas. ((400*120)=48000)+((120*84)=10080)+((84*10=840) params
  - >60K parámetros

DESVANECIMIENTO / EXPLOSIÓN DEL GRADIENTE

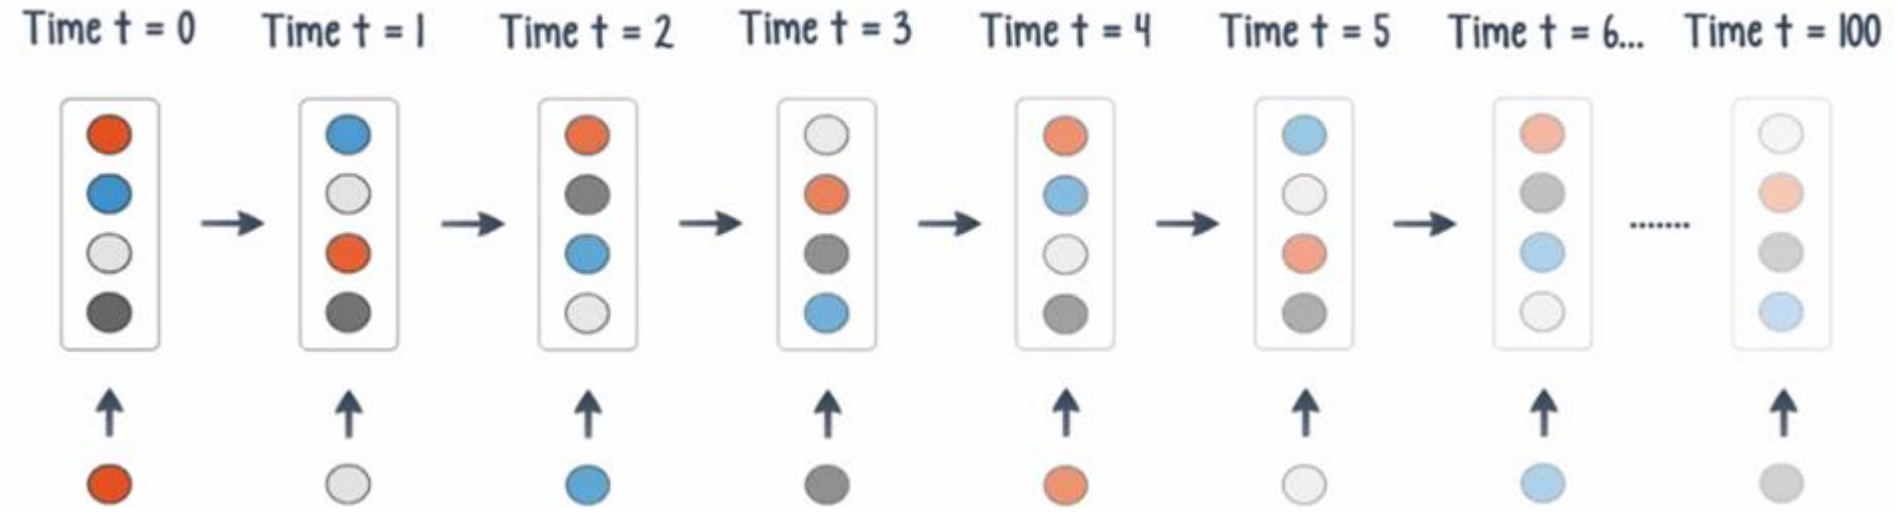

medium.com/@anishsingh20/the-vanishing-gradient-problem-48ae7f501257

→ https://www.youtube.com/watch?time_continue=14&v=SKMpmAOUa2Q

UNIVERSIDAD ICESI

DESVANECIMIENTO / EXPLOSIÓN DEL GRADIENTE

- **Problema del desvanecimiento del gradiente**: A medida que las redes son más profundas, la multiplicación sucesiva del back propagation hace que los gradientes se acerquen cada vez a valores infinitesimalmente pequeños, lo que conlleva a un empeoramiento en los resultados. Se encuentra con funciones de activación tradicionales (logit, tanh)
- **Problema de la explosión del gradiente**: problema análogo con funciones de activación que pueden tener gradientes importantes muy importantes
- Las primeras capas son las más importantes ya que aprenden los patrones de base, pero son entonces las más difíciles de entrenar → Tiempo de entrenamiento alto y degradación de los resultados del modelo

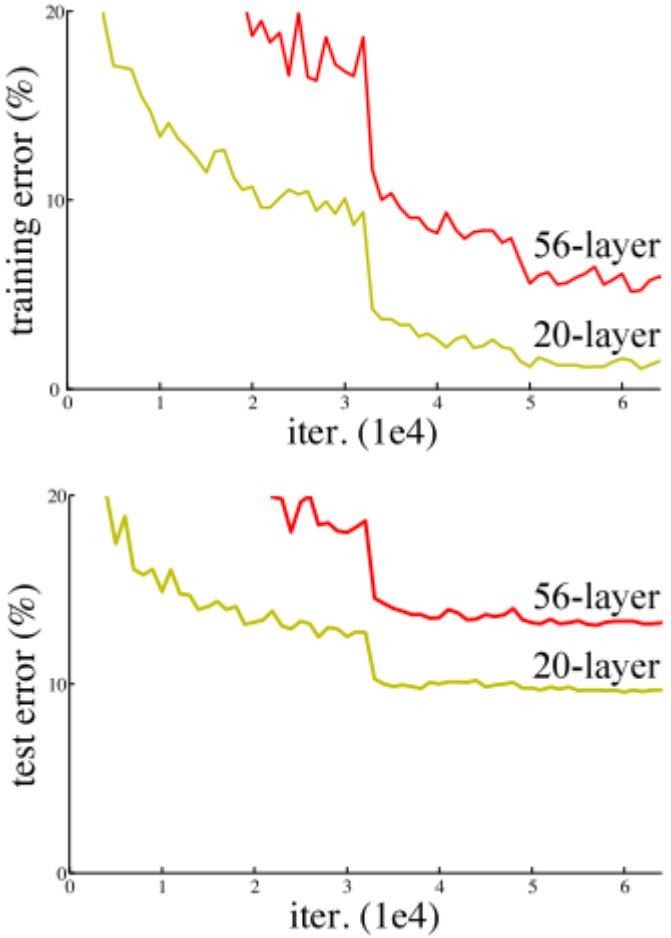

UNIVERSIDAD ICESI

DESVANECIMIENTO / EXPLOSIÓN DEL GRADIENTE

- Técnicas para combatirlo:
  - Pre entrenar capa por capa (años 90s)
  - RBMs (Restricted Boltzman Machines – 2006, Hinton) y Deep Belief Networks
  - Dejar de usar sigmoide y tanh: usar ReLUs que solo saturan en un sentido
  - Agregar una capa de salida en la mitad del modelo para agregar una **supervisión adicional**
  - Inicialización de los pesos (**Xavier**): usar factor multiplicativo $\sqrt{1/n}$, donde n es el numero de entradas de la capa en cuestión.
  - **Batch normalization**: los inputs de las capas son estandarizados para asegurar valores de gradientes altos
  - Conexiones **residuales** (ResNet)

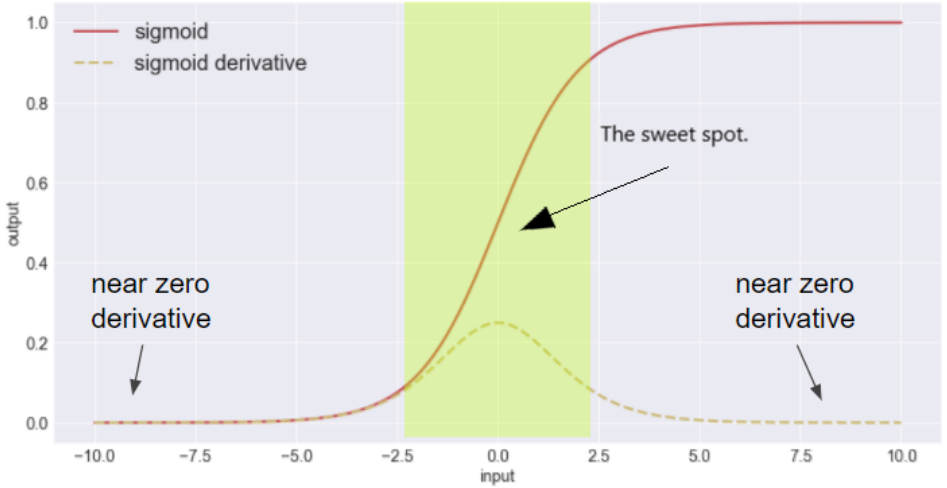

https://towardsdatascience.com/intuit-and-implement-batch-normalization-c05480333c5b

DESVANECIMIENTO / EXPLOSIÓN DEL GRADIENTE

- **Batch normalization**:
  - Los inputs de las capas son estandarizados para asegurar valores de gradientes altos. Se normalizan los valores antes de la función de activación de la capa anterior (los Zs) no después (los As)
  - Permite:
    - reducir el tiempo de entrenamiento
    - utilizar mayores learning rates
    - Regularizar (ruido de mini batches)
  - keras.layers.BatchNormalization,
  - tf.layers.batch_normalization
  - tf.nn.batch_normalization
  - Parámetro dentro de DNNClassifier y DNNRegressor

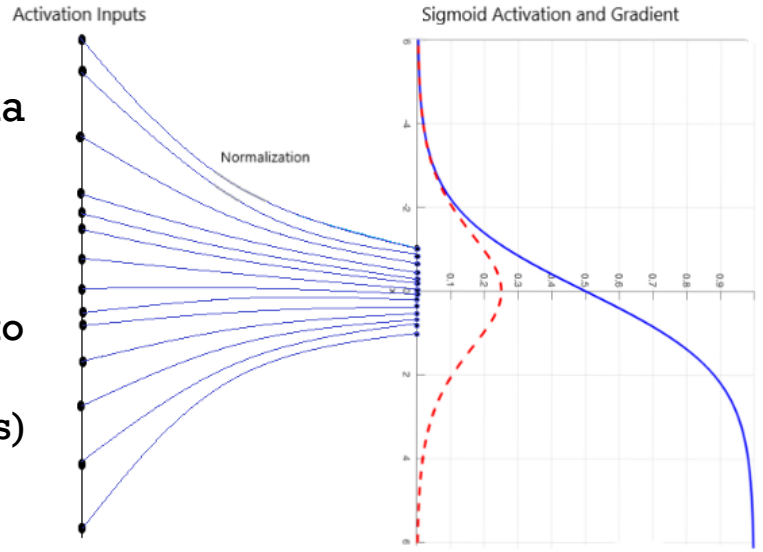

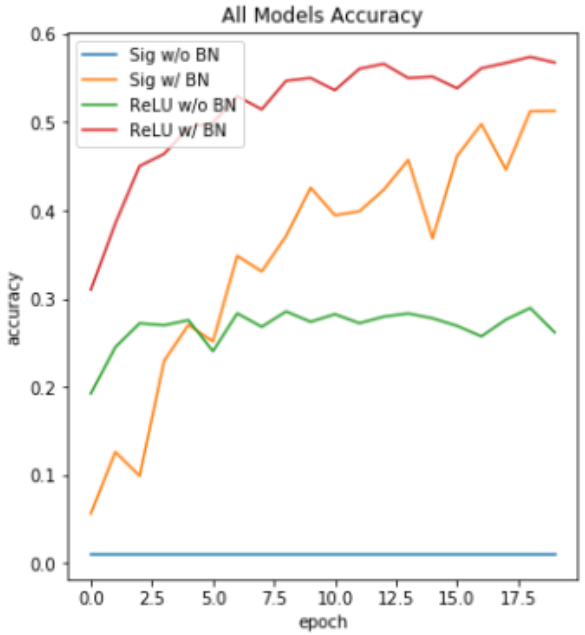

https://towardsdatascience.com/intuit-and-implement-batch-normalization-c05480333c5b

ALEXNET

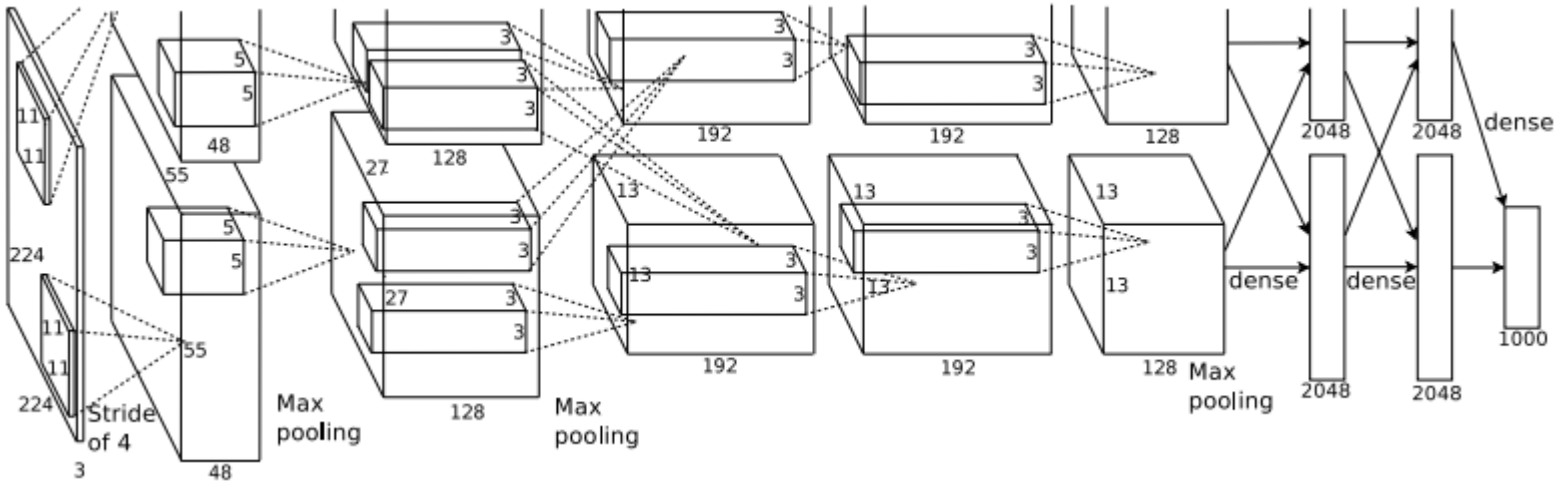

- A. Krizhevsky, I. Sutskever, and G. Hinton, ImageNet Classification with Deep Convolutional Neural Networks, NIPS 2012
  - Ganador del challenge ILSVRC 2012 (15,4% de error vs 26,2% del segundo). Desató la moda del DL
  - Usó ReLU, dropout, SGD con momentum, weight decay del learning rate, Softmax y data augmentation
  - 1,2 millones de imágenes de entrenamiento, 1000 clases. 6 días de entrenamiento en 2 GPUs GTX 580 de manera paralela (cada una se ocupa de la mitad de la red)
- Arquitectura:
  - Conv 11x11x95 con stride 4, seguida de MaxPooling 3x3 con stride 2 → 55x55x96
  - Conv 5x5x256 SAME padding, seguida de MaxPooling 3x3 con stride 2 → 27x27x256
  - Conv 3x3x384 SAME padding, seguida de otra Conv 3x3x384 SAME padding → 13x13*384
  - Conv 3x3x256 SAME padding, seguida de MaxPooling 3x3 con stride 2 →13x13x256
  - Salida convolucional aplanada en 9216 neuronas que entran a dos capas densas sucesivas de 4096 y 4096 neuronas
  - Salida de la red con una capa Softmax de 1000 neuronas
  - > 60 millones de parámetros (solo posible al tener un dataset de entrenamiento tan grande)

VGG-16

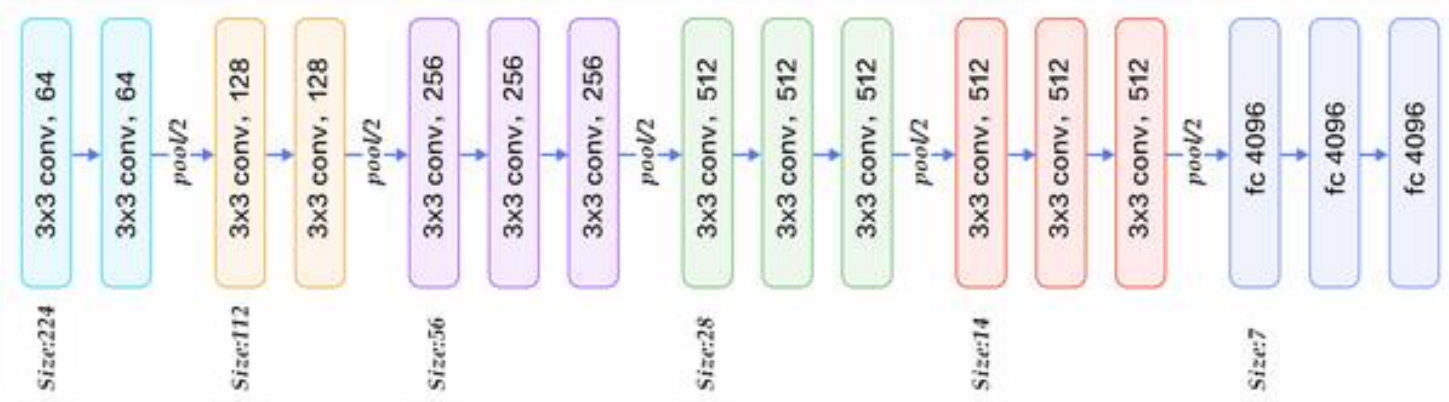

- K. Simonyan and A. Zisserman, Very Deep Convolutional Networks for Large-Scale Image Recognition, ICLR 2015
  - 2o puesto ILSVRC 2014, 7,3%
  - Usó Convs 1x1 para reducción de profundidad de los feature maps, Softmax
- Arquitectura: Simplicidad y profundidad, todas las capas se basan en Convs con filtros 3x3 con stride 1 y SAME padding, seguidos de MaxPooling 2x2 con stride 2)
  - 1 bloque de 2 Conv 3x3x64 seguido de MaxPooling → 112x112x64
  - 1 bloque de 2 Conv 3x3x128 seguido de MaxPooling → 56x56x128
  - 1 bloque de 3 Conv 3x3x256 seguido de MaxPooling → 28x28x256
  - 1 bloque de 3 Conv 3x3x512 seguido de MaxPooling → 14x14x512
  - 1 bloque de 3 Conv 3x3x512 seguido de MaxPooling → 7x7x512
  - Salida convolucional aplanada en 25088 neuronas que entran a dos capas densas sucesivas de 4096 y 4096 neuronas
  - Salida de la red con una capa Softmax de 1000 neuronas
  - > 138 millones de parámetros (solo posible al tener un dataset de entrenamiento tan grande)

TALLER MNIST CON CNN EN KERAS

Programar una red convolucional con el API secuencial de Keras con la siguiente arquitectura:

- Una capa de entrada de 28x28
- Una capa convolucional con 32 filtros 3x3 con ReLUs, con stride 1 (VALID)
- Una capa de MaxPooling 2x2 con stride 2
- Una capa convolucional con 64 filtros 3x3 con ReLUs, con stride 1 (VALID)
- Una capa de MaxPooling 2x2 con stride 2
- Una capa Flatten que aplane los datos
- Una capa Densa de 64 neuronas con ReLU
- Dropout con probabilidad 30%
- Una capa Densa de salida de 10 neuronas con Softmax
- Utilice un optimizador RmsProp y una función de costo de categorical cross-entropy, con un porcentaje del dataset de entrenamiento del 10% dedicada a validar el aprendizaje

TALLER PERROS Y GATOS CON CNN EN KERAS

Entrenar una red convolucional que permita clasificar imágenes de perros y gatos.

UNIVERSIDAD ICESI

RESNET

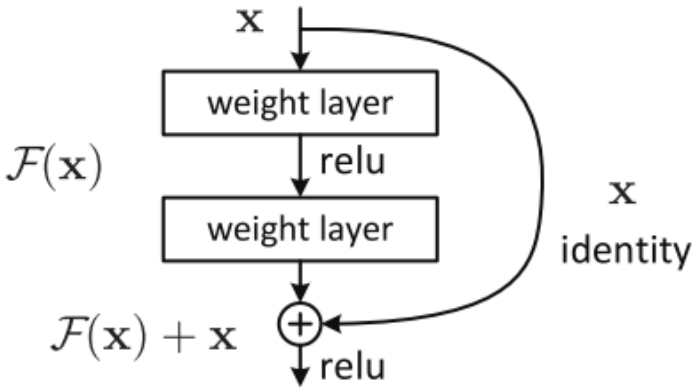

- Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun, Deep Residual Learning for Image Recognition, CVPR 2016
  - Ganador ILSVRC 2015, 3,6% error (menor al error humano – entre 5% y 10%) y COCO 2015: ambas en las categorías de detección y localización,
  - Agregar una nueva capa no debería degradar los resultados (e.g. capa identidad)
  - Combate el problema del **vanishing gradient** efectivamente
  - Converge más rápidamente que los modelos correspondientes sin conexiones residuales
- Arquitectura
  - **Bloque residual:** proyecta la salida de una capa convolucional como parte de la entrada de la capa que se encuentra dos pasos mas adelante y se combina con la agregación lineal de la misma antes de la función de activación correspondiente (ver imagen).
  - Los bloques residuales se ponen uno después de otro, tantos como se quieran (se entrenó un ResNet con 1001 bloques), seguidos por capas de MaxPooling para reducir las dimensiones del filtro convolucional mientras se aumenta el número de filtros

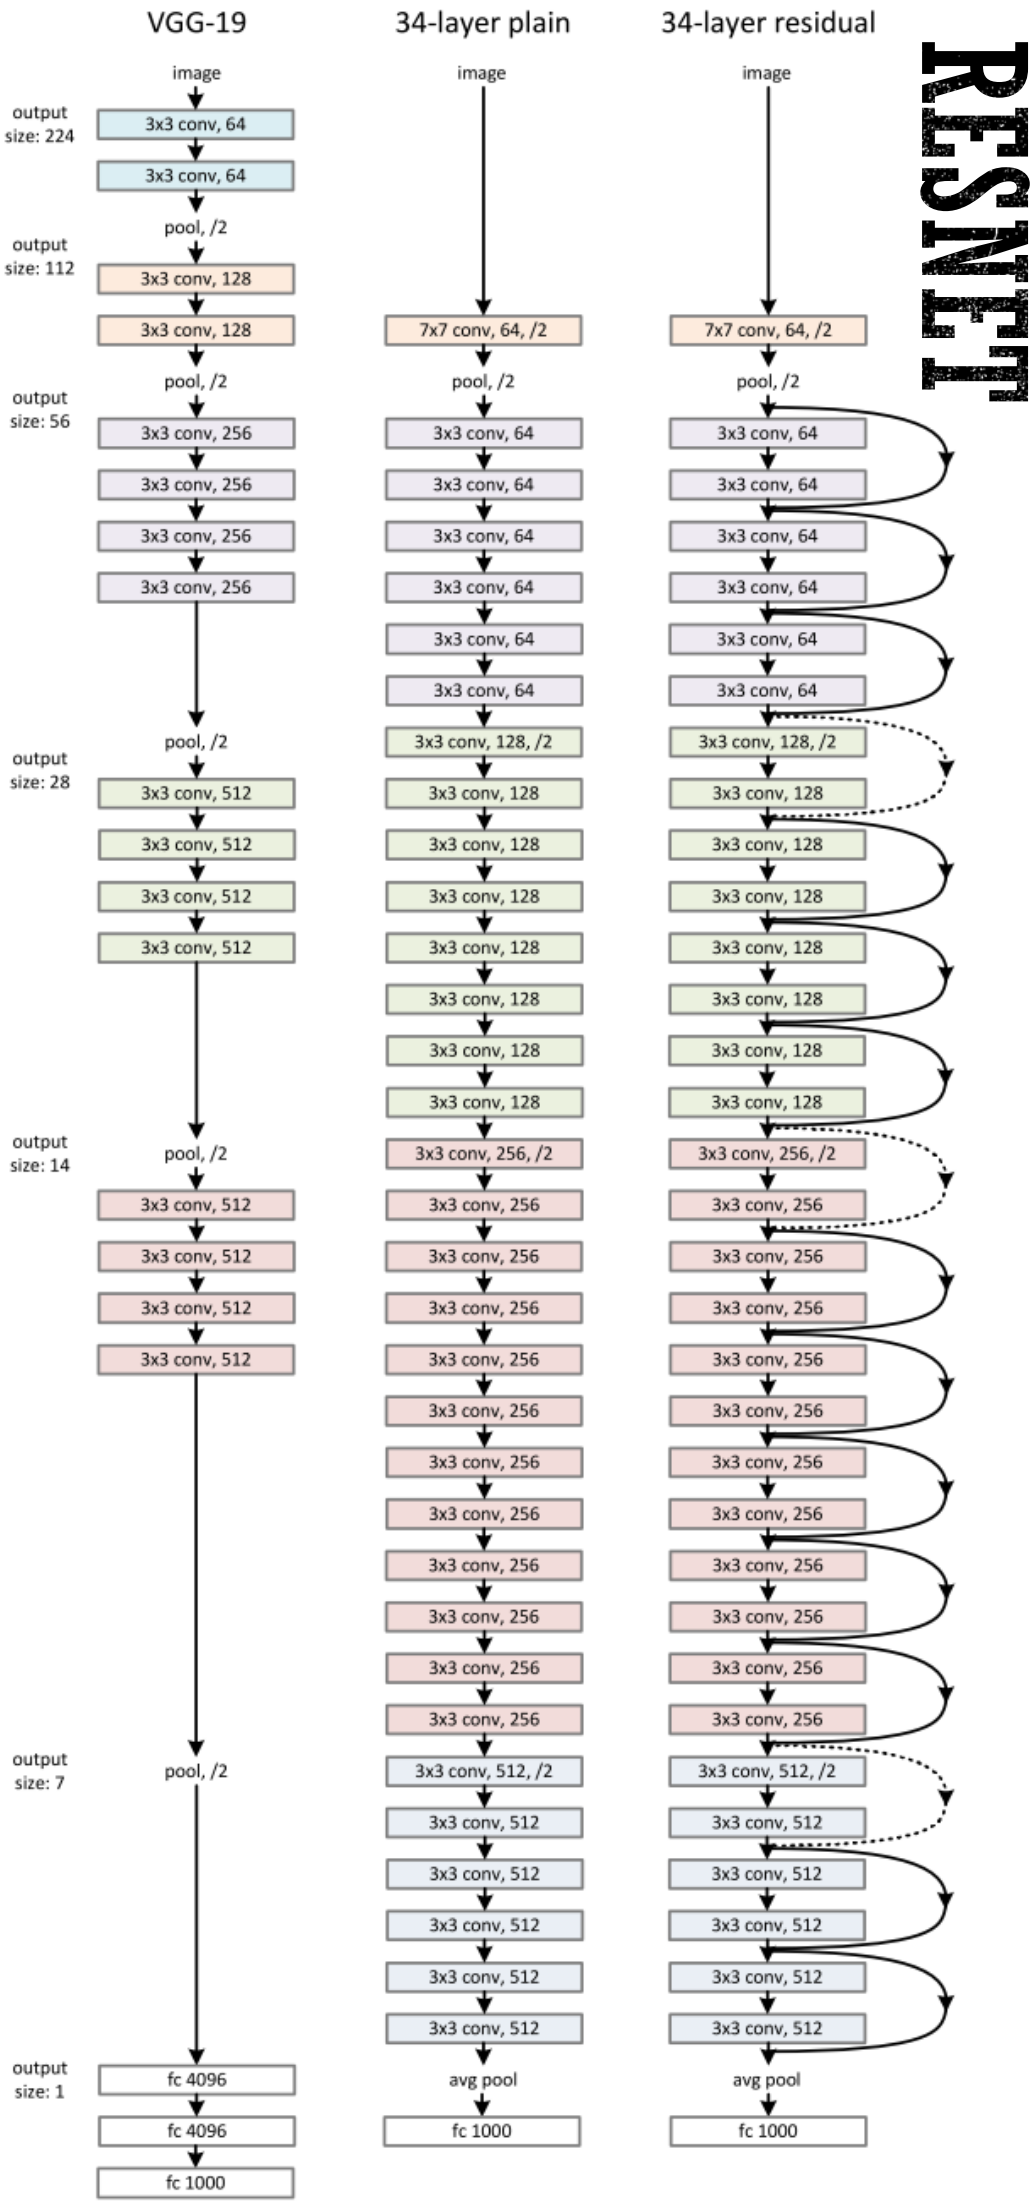
VGG-19
34-layer plain
34-layer residual
RESNET
image
output size: 224
3x3 conv, 64
3x3 conv, 64
pool, /2
output size: 112
3x3 conv, 128
3x3 conv, 128
pool, /2
output size: 56
3x3 conv, 256
3x3 conv, 256
3x3 conv, 256
3x3 conv, 256
pool, /2
output size: 28
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
pool, /2
output size: 14
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
pool, /2
output size: 7
fc 4096
fc 4096
fc 1000
output size: 1
7x7 conv, 64, /2
pool, /2
3x3 conv, 64
3x3 conv, 128, /2
3x3 conv, 128
3x3 conv, 256, /2
3x3 conv, 256
3x3 conv, 512, /2
3x3 conv, 512
avg pool
fc 1000

CONVOLUCIONES 1X1

- En el caso de un feature map de entrada de profundidad 1 (e.g., imagen en escala de grises) → Multiplicación por escalar
- En el caso de múltiples canales de entrada → producto punto de los P1 canales de entrada por los filtros 1x1xP1
- La función de activación se encarga de transformar el valor escalar final
- Se pueden aplicar P2 filtros convolucionales 1x1, con P2<P1, de tal manera que se pasa de P1 canales a P2 canales.
- Para reducir la representación tenemos entonces las capas Pooling que reducen el alto y ancho, y las convoluciones 1x1, que reducen la profundidad

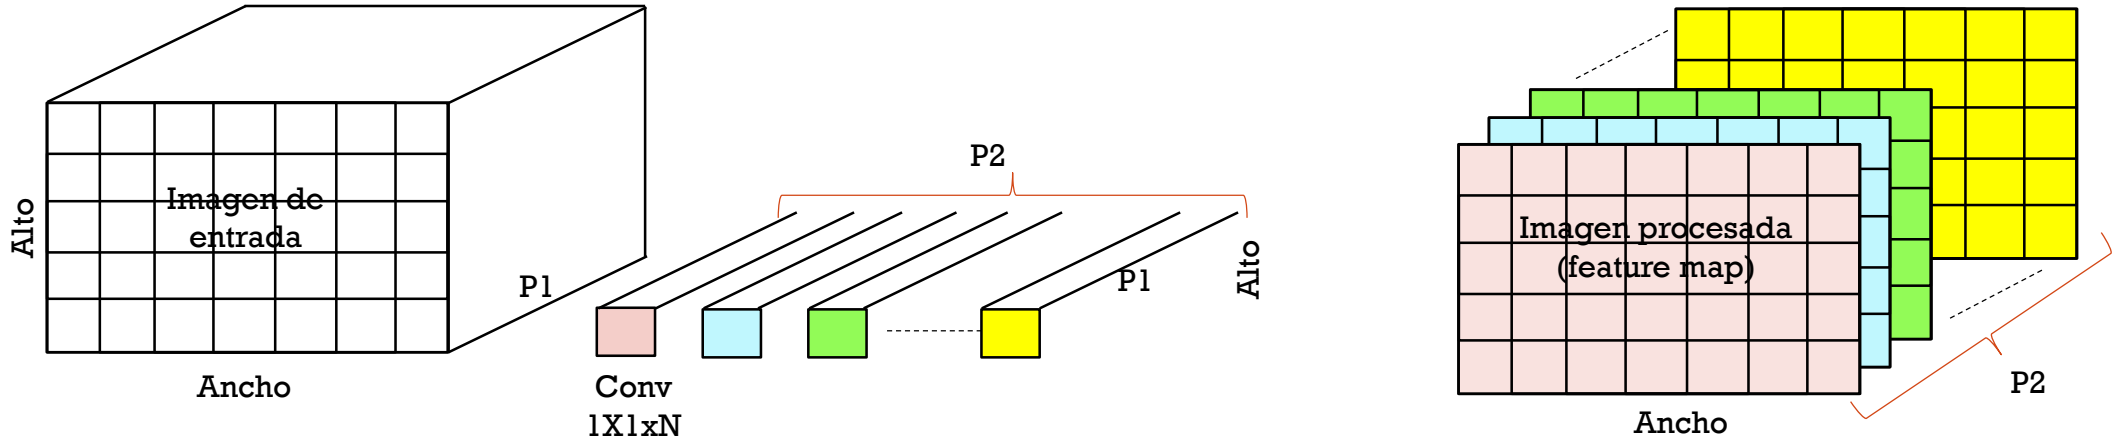

CONVOLUCIONES 1X1

- Si vamos a aplicar una convolución SAME de 32 filtros 5x5 a un feature map de entrada de 28x28 con 192 canales de profundidad,
  - ¿Cuáles van a ser las dimensiones del tensor de salida?
  - ¿Cuántos cálculos se necesitan?
- Si utilizamos una convolución 16 filtros 1x1 intermedia ("bottleneck"), seguida de una convolución SAME con 32 filtros 5x5, ¿qué tanto mejora la situación?
- Se puede reducir el tamaño de representación y de cálculos sin perjudicar el performance de la clasificación

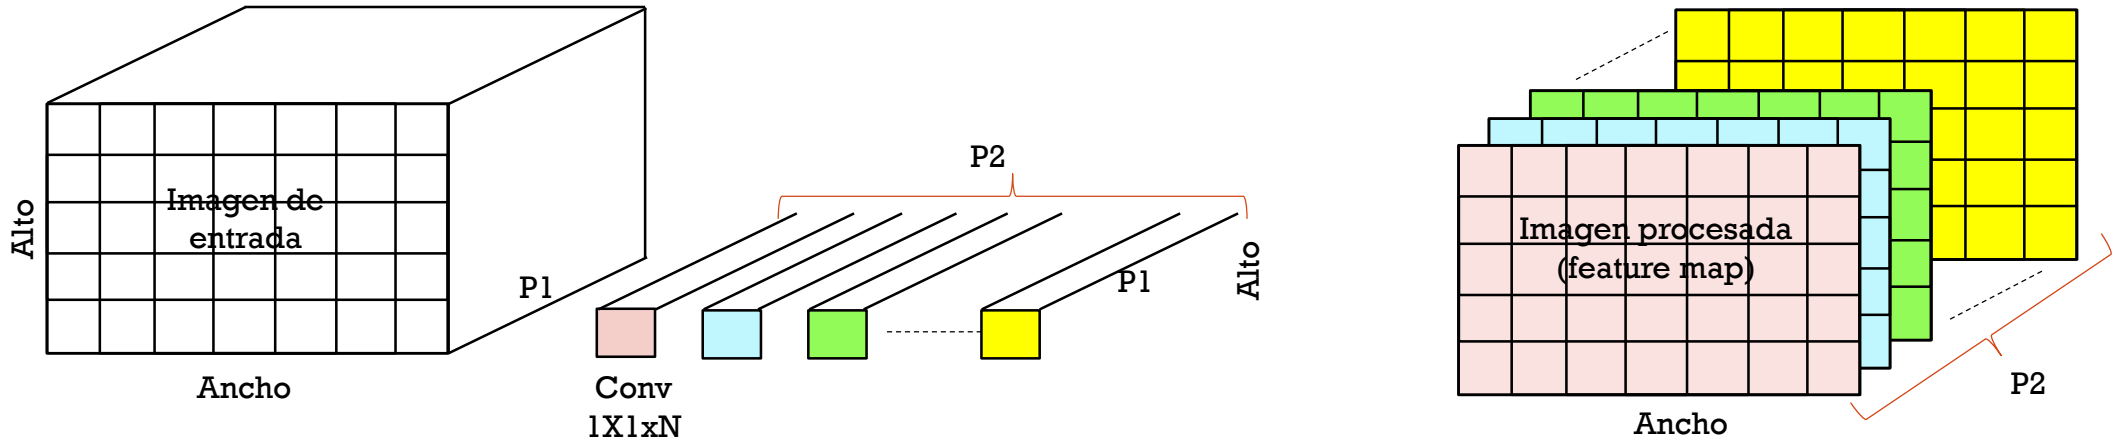

INCEPTION

- C. Szegedy et al., Going deeper with convolutions, CVPR 2014
  - Idea de base: por qué hacer una selección entre una conv 1x1, 3x3, 5x5 o un pooling (same), si podemos hacerlas todas a la vez?
  - Definición de módulos que se reutilizan a lo largo de la red (se actualizan en Inception v2, v3, v4)
  - Cada modulo combina los resultados de 4 tipos de secuencias de tratamiento convolucional, cada debe producir feature maps de las mismas dimensiones, que se concatenan en profundidad de canales
  - Se utilizan adicionalmente clasificadores auxiliares temprano en la red para asegurarse que los features en las capas intermediarias no sean tan alejados de lo que se busca.

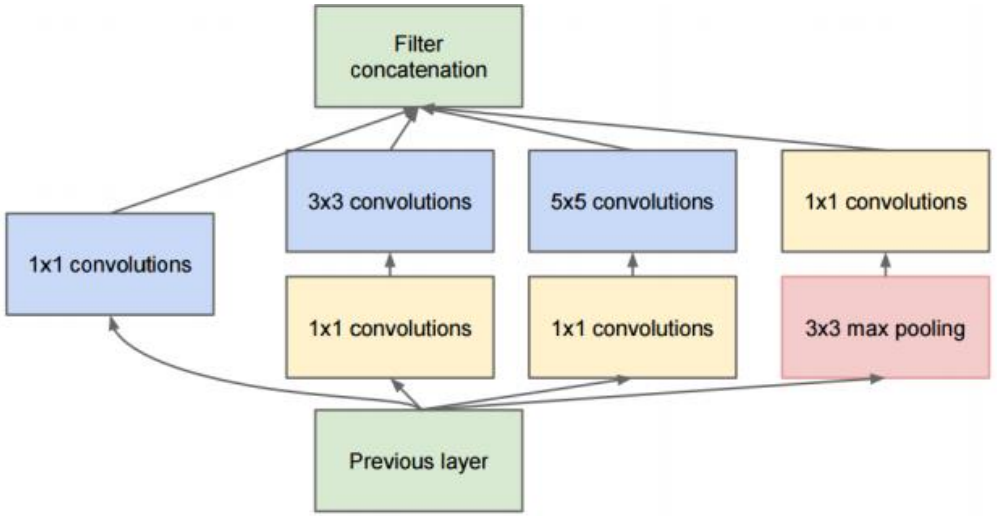

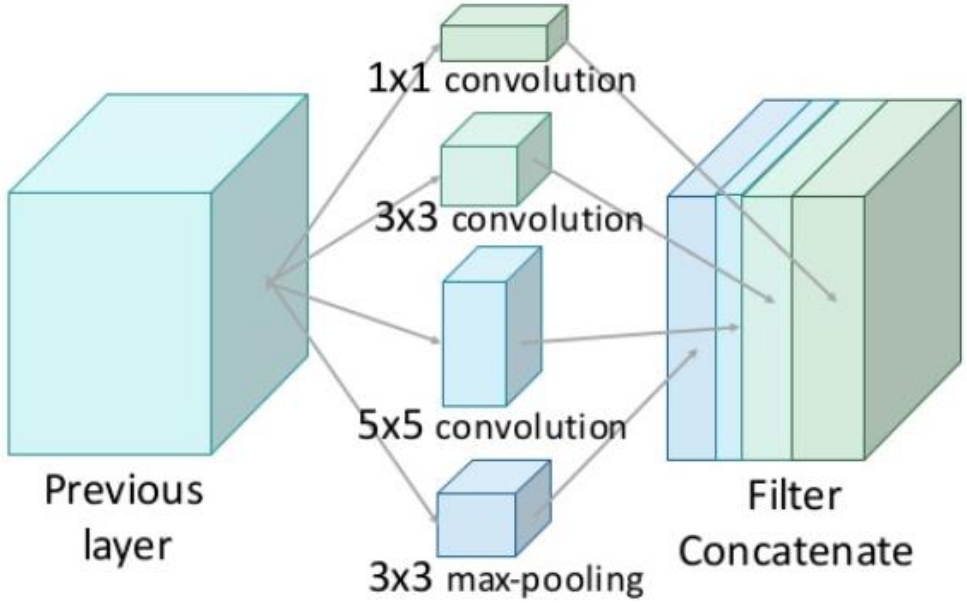

Szegedy et al, 2014

INCEPTION

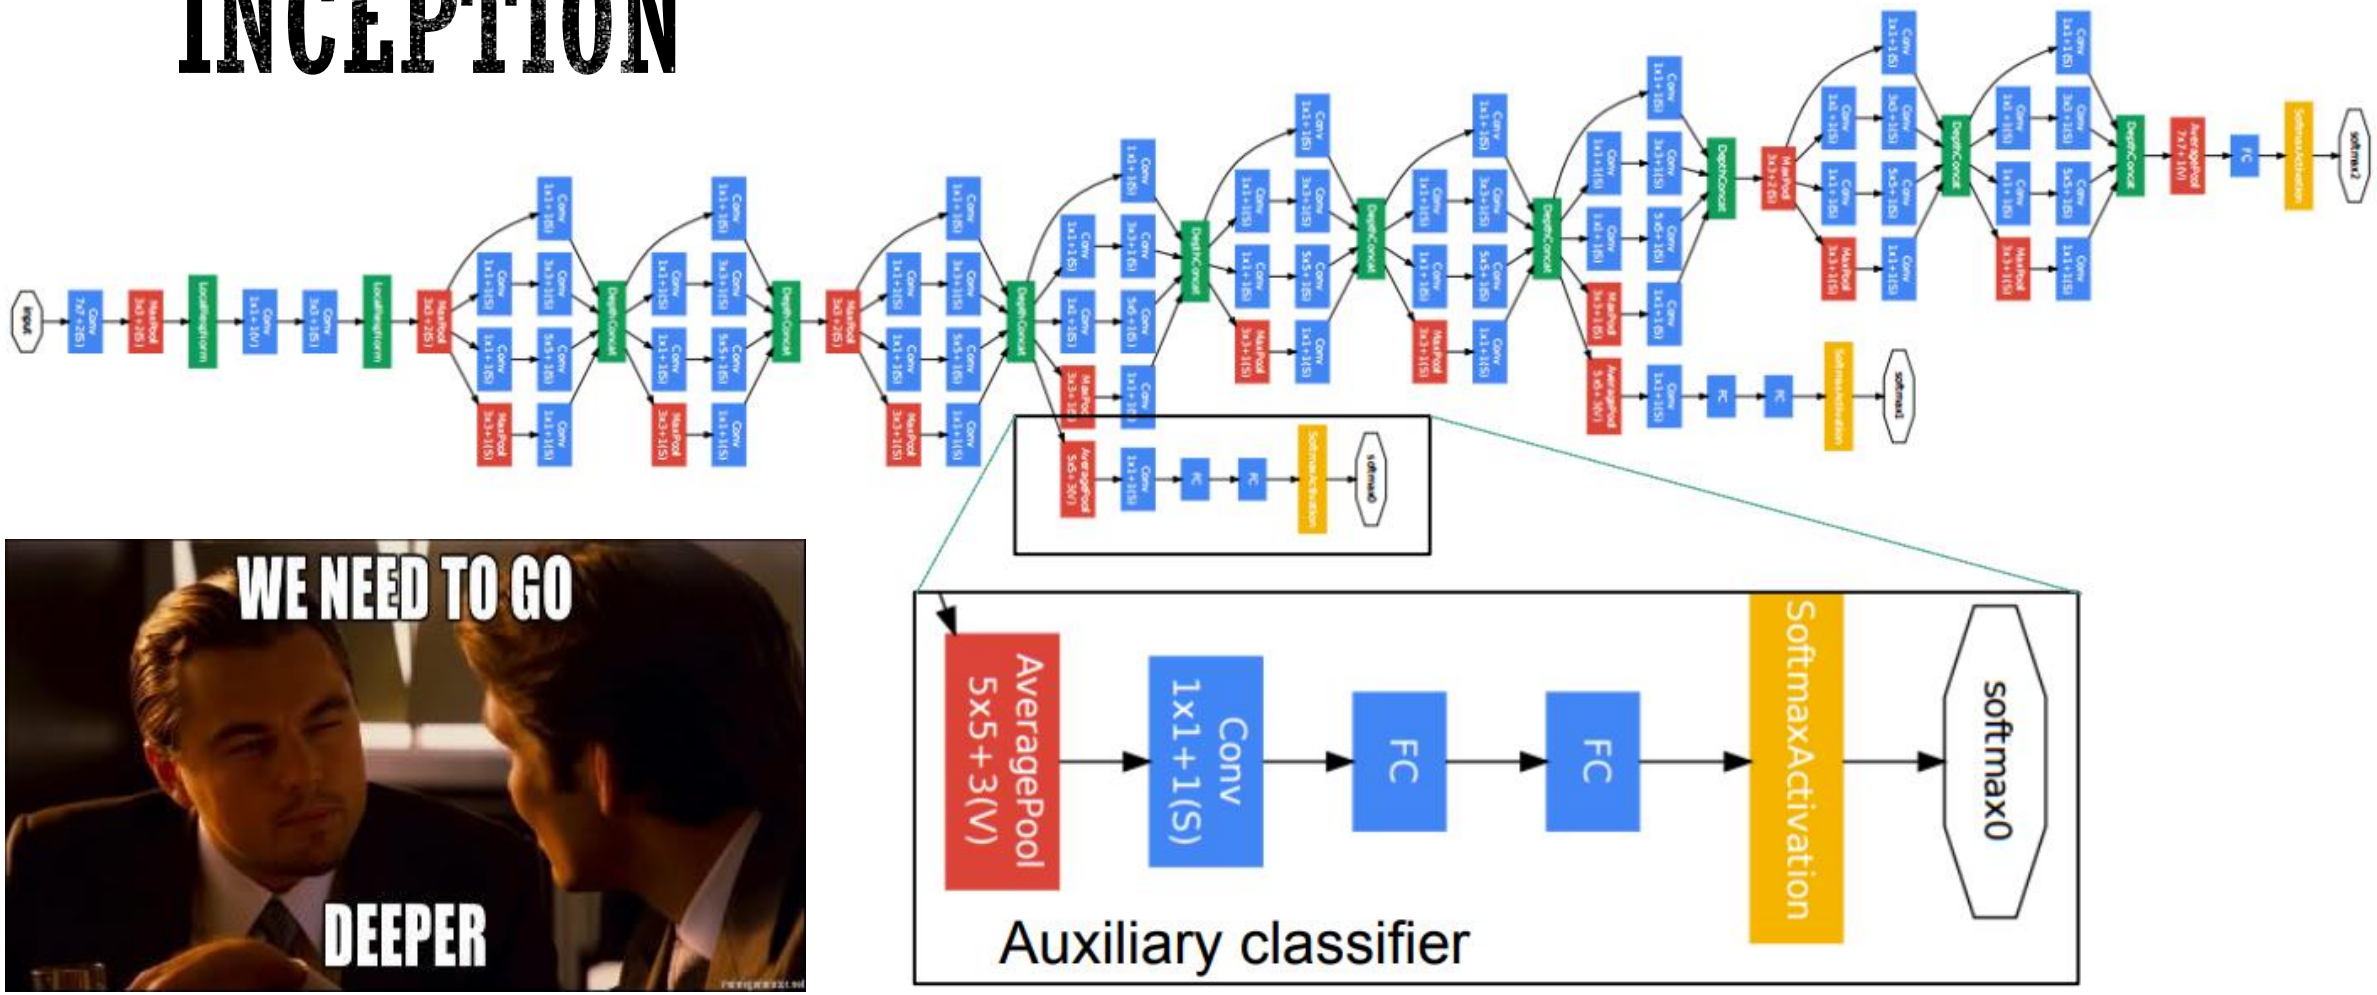

Szegedy et al, 2004

GENERALIDADES ARQUITECTURALES

- Globalmente las arquitecturas tienen dos partes: una convolucional que sirve para extraer features, y una densa que sirve para predicción
- A medida que se adquiere profundidad en la capa, la altura y el ancho de los feature maps disminuyen, mientras que el número de canales aumenta
- Es común encontrar capas de pooling después de 1, 2, o 3 capas convolucionales como método de reducción del tamaño de los feature maps
- Los filtros no deben ser muy grandes ya que pueden ignorar información relevante para las capas subsiguientes (e.g. filtro 11x11 de Alexnet en la primera Conv)

AGENDA

Deep Learning

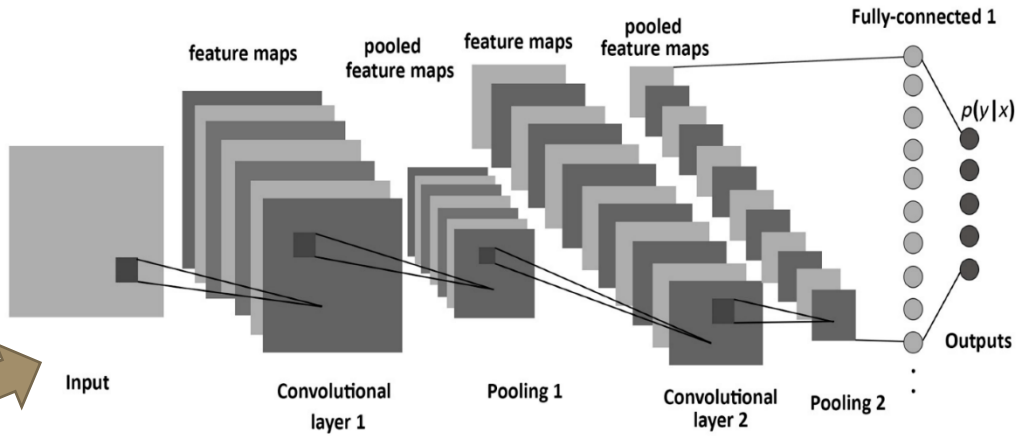

Redes convolucionales

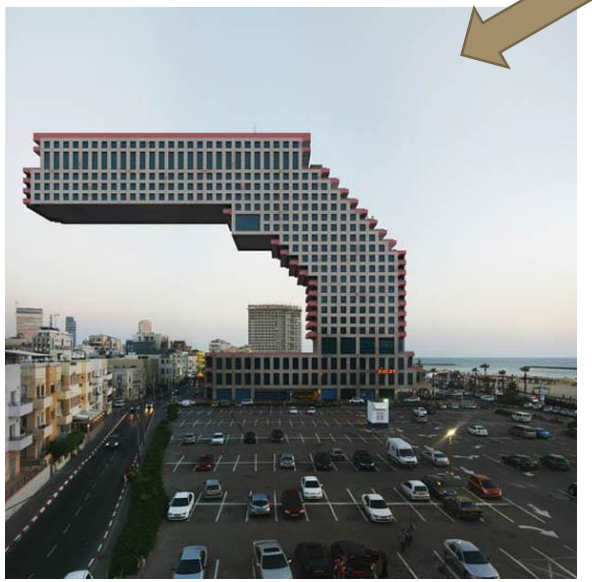

Arquitecturas convolucionales

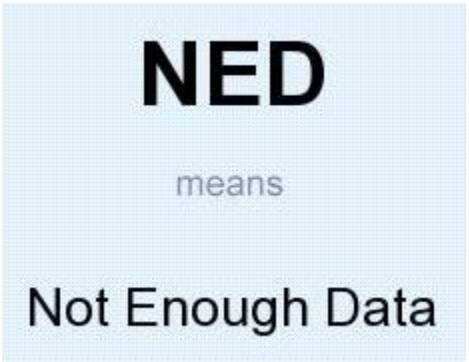

Limitaciones de datos

UNIVERSIDAD ICESI

DATOS LIMITADOS

UNIVERSIDAD ICESI

DATOS LIMITADOS

- Si la complejidad de la tarea a resolver es alta, el número de parámetros y la profundidad de la red debe ser elevado
- Necesidad de grandes conjuntos de datos para poder entrenar una red profunda
- Si no hay suficiente puede tender al overfitting o no converger
- A menudo, no hay datos suficientes…

DATOS LIMITADOS → HAND ENGINEERING

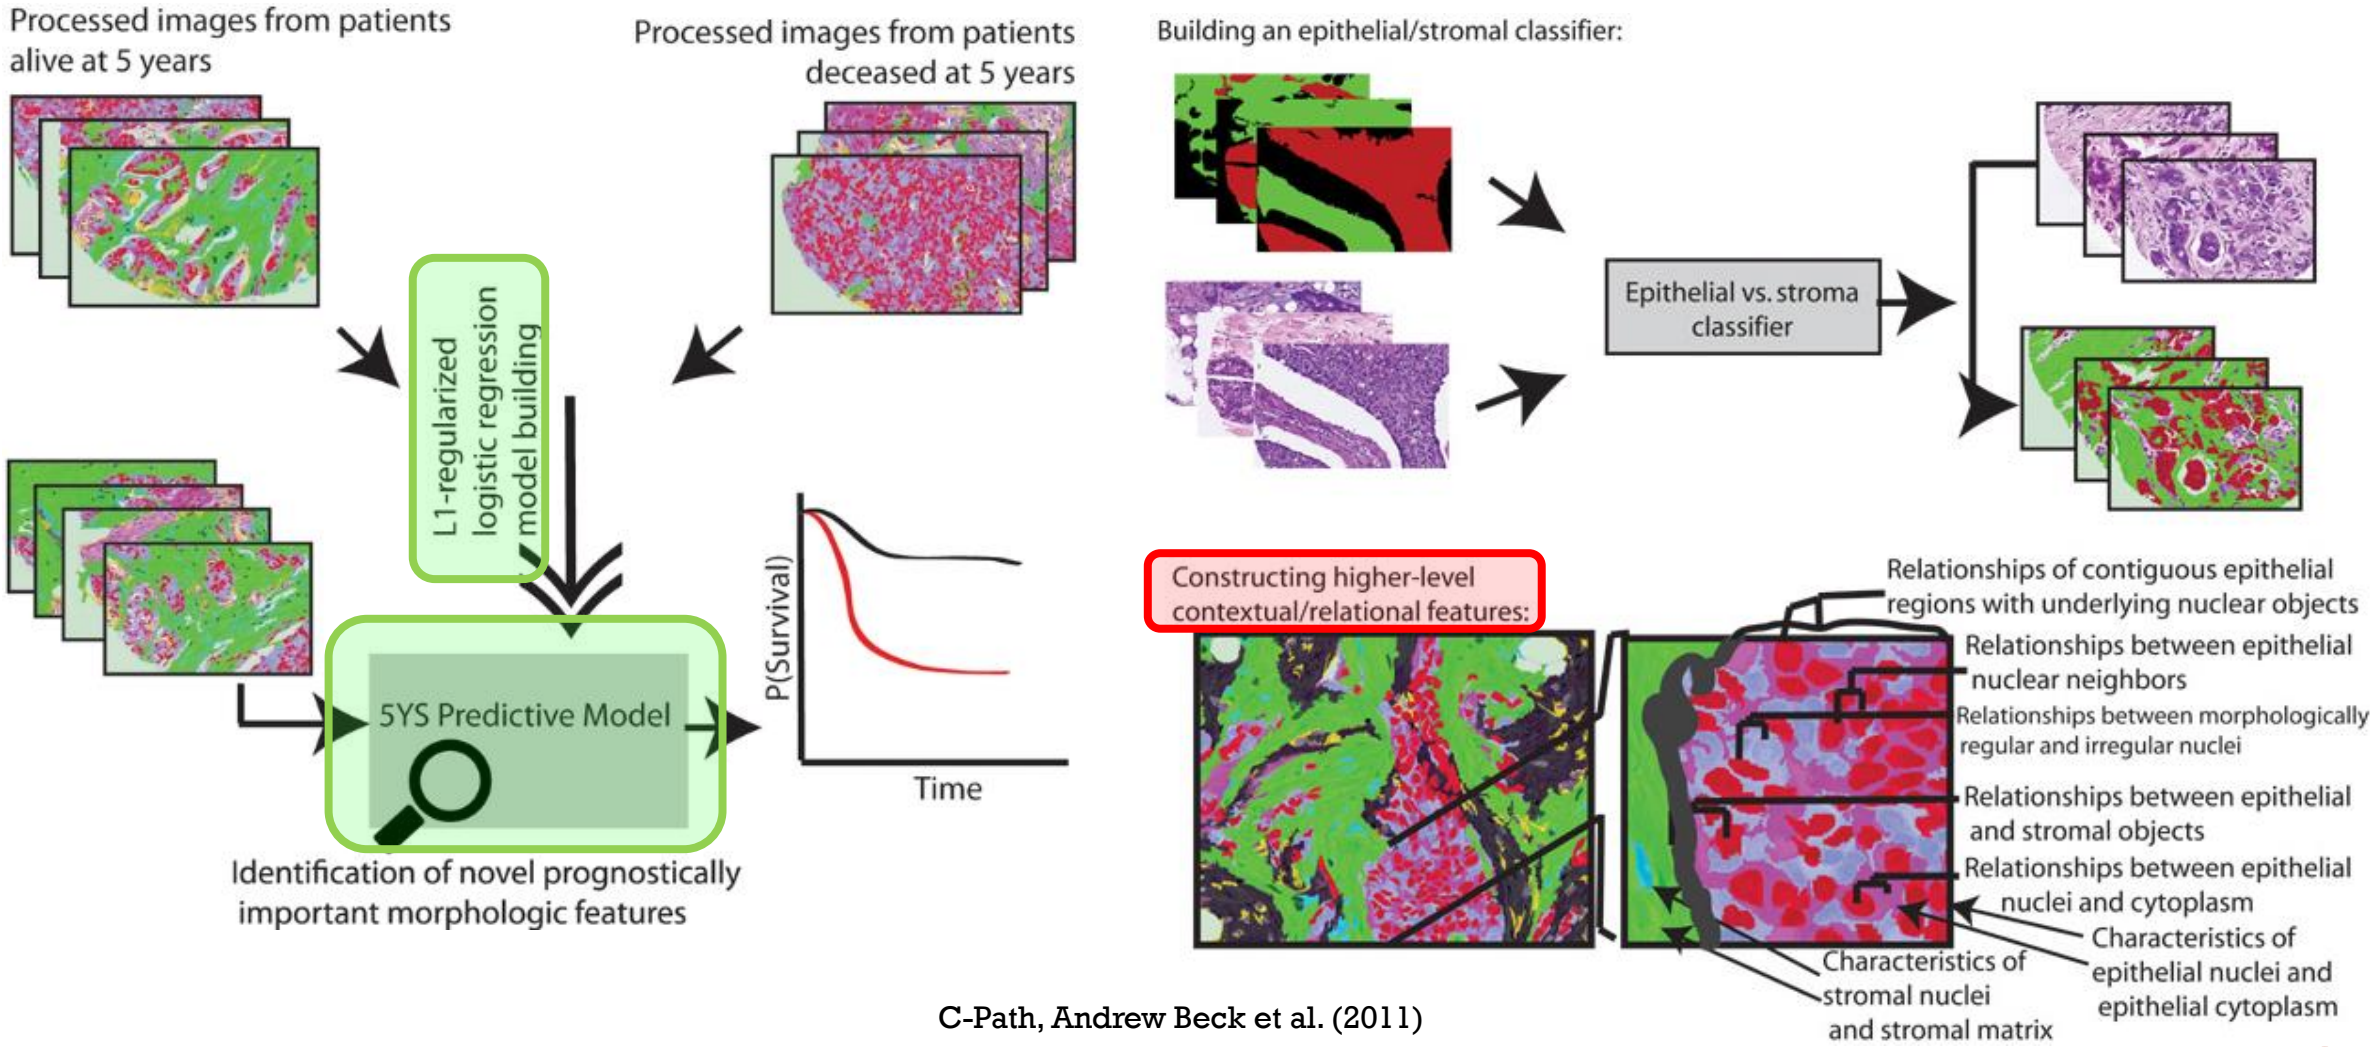

C-Path, Andrew Beck et al. (2011)

DATA AUGMENTATION

- Agrandar el dataset a partir de transformaciones plausibles de los datos disponibles:
  - Espejos
  - Translaciones
  - Rotaciones
  - Deformaciones
  - Recorte
  - Coloraciones
  - Iluminación
  - Zoom
  - Cambio de fondo
  - Agregar ruido
- **Objetivo**: mejorar los modelos entrenados

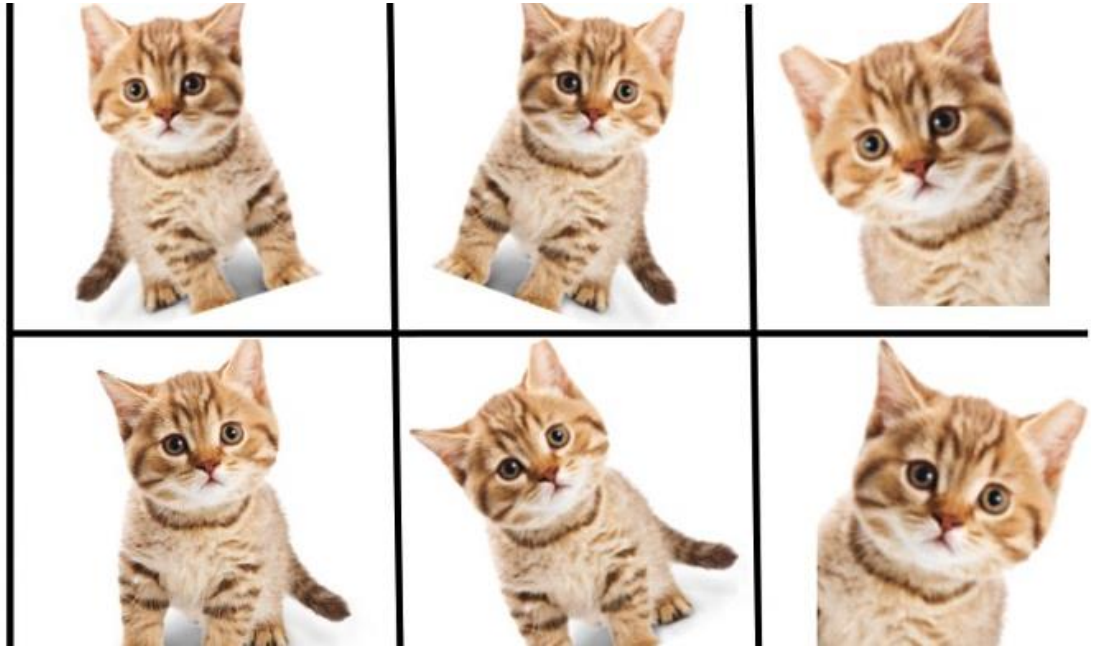

https://medium.com/nanonets/how-to-use-deep-learning-when-you-have-limited-data-part-2-data-augmentation-c26971dc8ced

UNIVERSIDAD ICESI

DATA AUGMENTATION

- No es lo mismo que tener datos nuevos: hay una correlación entre los datos originales y los aumentados
- Aún cuando se tiene un gran volumen de datos, el data augmentation puede ayudar a evitar sesgos de los datos (e.g. fotos tomadas siempre desde el mismo ángulo)
- **Offline augmentation**: creación y persistencia de los datos aumentados
- **Online augmentation**: los datos son distorsionados durante el entrenamiento después de ser cargados en memoria y antes de ser presentados al algoritmo de aprendizaje

TRANSFER LEARNING

- El entrenamiento de una red convolucional importante requiere de:
  - Un conjunto grande de datos (e.g. 15 millones de imágenes de ImageNet)
  - Una infraestructura computacional importante en cuanto a recursos de procesamiento (GPUs, memoria)
  - Tiempo de entrenamiento
- Idea: poder reutilizar trabajos previos de entrenamiento de redes

TRANSFER LEARNING

Re-entrenar (fine tuning)

Congelar

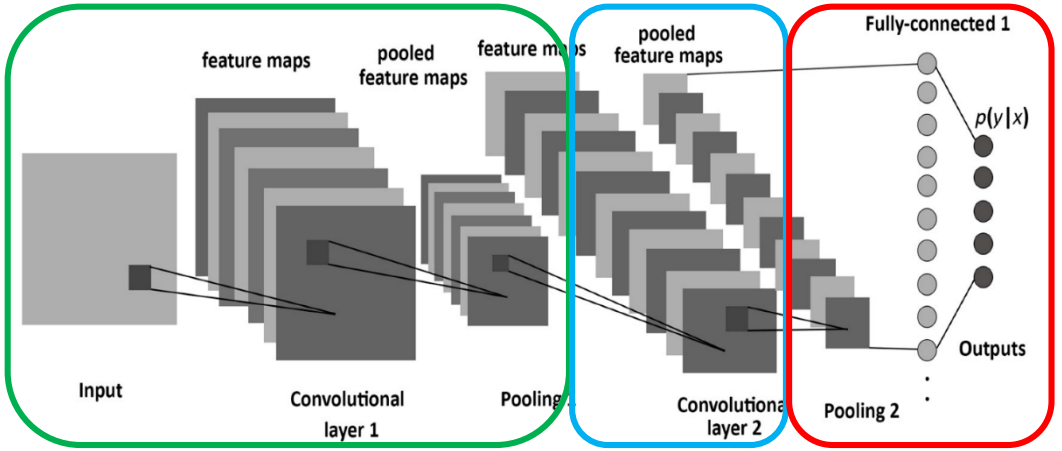

Remplazar

- En las CNNs, se tienen diferentes niveles de abstracción en cada capa, dada su profundidad
- Los filtros aprendidos pueden ser lo suficientemente generales como para poder ser aplicados a otras tareas con otros datasets:
  - Reutilizar una gran parte de la arquitectura de una red original (se congelan las capas correspondientes para que no sean reentrenadas)
  - Eliminar capas densas finales de clasificación Reentrenar un subconjunto de capas
  - Reentrenar las últimas capas convolucionales que hayan aprendido filtros mas específicos a la tarea original

TRANSFER LEARNING

- Con redes convolucionales, una manera de ahorrar en tiempo de cómputo, en el caso de no tener que reentrenar las capas convolucionales, consiste en pasar el training set por la red importada, aplanar la salida y grabar cada feature map aplanado en archivo. Luego se crea una red "shallow" que consista en unas cuantas capas densas, que se entrenará sobre los archivos previamente procesados.
- El número de capas a reentrenar depende de la cantidad de datos disponibles. Entre mas datos, se vuelve posible reentrenar mas capas finales
- Es posible reentrenar toda la red, simplemente utilizando los valores de los parámetros transferidos como inicialización de los pesos de la red.

TALLER PERROS Y GATOS CON TRANSFER LEARNING

Utilizar una red convolucional VGG16 previamente entrenada como punto de partida para crear un modelo de clasificación que discrimine entre imágenes con perros de imágenes con gatos.

UNIVERSIDAD ICESI

GRACIAS

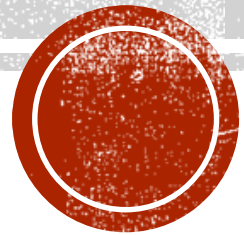

UNIVERSIDAD ICESI

REFERENCIAS

- *Learning TensorFlow*, Tom Hope, Yehezkel S. Resheff & Itay Lieder, O'Reilly 2017
- *Introduction to TensorFlow*, Chris Manning & Richard Socher, Lecture 7 of the CS224n course at Stanford University, 2017
- *Hands-On Machine Learning with Scikit-Learn and TensorFlow*, Aurélien Géron, 2017
- *Machine learning with TensorFlow*, Nishant Shukla, Manning, 2018
- *Python Machine Learning (2nd ed.)*, Sebastian Raschka & Vahid Mirjalili, Packt, 2017
- *TensorFlow for Deep Learning*, Charath Ramsundar & Reza Bosagh Zadeh, O'Reilly, 2018
- *Deep Learning with Python*, Francois Chollet, Manning 2018
- *Neural Networks and Deep Learning,* Andrew Ng, Coursera, 2017